Carga de datos

El dataset Iris se descargó exitosamente desde la URL pública: https://raw.githubusercontent.com/uiuc-cse/data-fa14/gh-pages/data/iris.csv

Dimensiones: 150 filas × 5 columnas (4 numéricas + species)

Resultados de la Etapa de Limpieza

Verificación	Resultado	Acción Tomada
Valores Nulos	0 en todas las columnas	Ninguna
Registros Duplicados	3 duplicados encontrados	Eliminados (150 → 147 registros)
Outliers (IQR)	4 en sepal_width (índices 15, 32, 33, 60)	**Conservados** — son valores biológicamente válidos
Outliers (Z-score |z|>3)	1 en sepal_width (índice 15)	**Conservados** — no son errores de medición

Conclusión de limpieza: Los datos del dataset Iris ya estaban consistentes. Los valores detectados como "outliers" por IQR/Z-score en sepal_width corresponden a flores reales con anchos de sépalo atípicos pero válidos (ej. índice 15: *setosa* con sepal_width=4.4). No se eliminaron para no perder información biológica relevante. Solo se eliminaron los 3 registros duplicados exactos.

K-Means sin transformación (Datos Originales)

Método del Codo:

- Se observa una caída pronunciada de la inercia hasta **k=3**, después la pendiente se suaviza considerablemente.
- **k óptimo por codo: 3**

Índice Silhouette:

- Máximo en **k=2** (score = 0.6808), seguido de k=3 (score = 0.5526).
- **k óptimo por Silhouette: 2** (aunque k=3 es biológicamente conocido como el número correcto de especies).

Resultado con k=3:

Cluster	setosa	versicolor	virginica
0	0	48	14
1	50	0	0
2	0	2	36

- **Setosa** se agrupa perfectamente.
- Hay confusión entre *versicolor* y *virginica* (16 puntos mal clasificados).
- **Silhouette Score:** 0.5526
- **ARI vs especies reales:** 0.7302

K-Means después de PCA (2 componentes)

Varianza explicada:

- PC1: 92.46%
- PC2: 5.30%
- **Total: 97.76%** de la varianza original se conserva.

Método del Codo (PCA):

- Nuevamente el codo se observa claramente en **k=3**.

Índice Silhouette (PCA):

- Máximo en **k=2** (score = 0.7055), seguido de k=3 (score = 0.5976).
- **k óptimo por Silhouette: 2**

Resultado con k=3 en PCA:

Cluster	setosa	versicolor	virginica
0	0	3	36
1	50	0	0
2	0	47	14

- **Setosa** perfectamente identificada.
- Confusión similar entre *versicolor* y *virginica* (17 puntos mal clasificados).
- **Silhouette Score:** 0.5976
- **ARI vs especies reales:** 0.7163

Comparación de Resultados

Métrica	Datos Originales (k=3)	PCA (k=3)
ARI	0.7302	0.7163
NMI	0.7582	0.7419
Silhouette	0.5526	**0.5976**
Inercia	78.94	63.87

ARI entre ambos clusterings: 0.9803 → Los agrupamientos son prácticamente idénticos (casi 1.0).

Respuesta a las Preguntas

¿Obtuviste los mismos resultados de agrupamiento?

Sí, esencialmente los mismos resultados. El ARI de 0.98 entre ambos clusterings indica que las asignaciones de cluster son casi idénticas. Ambos métodos separan perfectamente a *setosa* y presentan la misma dificultad inherente al dataset: la superposición natural entre *versicolor* y *virginica*.

Ventaja práctica de aplicar PCA antes de K-Means:

1. **Visualización directa:** Al reducir a 2 dimensiones se pueden graficar los clusters y sus centroides de forma inmediata, algo imposible en 4D.
2. **Mayor Silhouette:** El score mejoró de 0.55 a 0.60, indicando clusters ligeramente más cohesionados y separados.
3. **Eficiencia computacional:** Menor dimensionalidad implica menos distancias que calcular en cada iteración de K-Means.

4. **Eliminación de redundancia:** PCA descorrelaciona las variables y concentra la información en componentes principales, descartando ruido potencial.
5. **Conservación de información:** Se mantiene el 97.76% de la varianza con solo 2 variables, facilitando la interpretación sin pérdida significativa de información.

Conclusiones

Resultados de la Limpieza

- Valores nulos: 0 en todas las columnas.
- Duplicados: 3 registros exactos eliminados (150 → 147).
- Outliers: 4 valores atípicos detectados en `sepal_width` por IQR, pero se conservaron porque corresponden a mediciones biológicamente válidas del dataset Iris.

¿Mismos resultados de agrupamiento?

Sí, los resultados son muy similares. El ARI entre ambos clusterings es cercano a 0.98,

indicando asignaciones prácticamente idénticas. Ambos métodos identifican perfectamente a setosa y presentan confusión esperada entre versicolor y virginica.

Ventaja práctica de PCA antes de K-Means

1. Visualización inmediata: Permite graficar clusters en 2D.
2. Mayor Silhouette: Mejor separación entre clusters.
3. Eficiencia: Menor costo computacional.
4. Eliminación de redundancia: Descarta ruido y correlaciones.
5. Conservación de información: ~98% de varianza en solo 2 dimensiones.

Nota sobre k óptimo

Codo: sugiere claramente k=3 en ambos casos.

Silhouette: sugiere k=2 porque versicolor y virginica son más similares entre sí.