Predicción de abandono de empleados mediante K Vecinos más Cercanos (KNN)

Base de datos: recursos_humanos.csv

Objetivo: analizar el abandono de empleados y construir un modelo predictivo que identifique empleados con mayor probabilidad de dejar la empresa.

Introducción

La rotación de personal representa un reto para Recursos Humanos porque la salida de empleados puede generar costos de contratación, capacitación y pérdida de experiencia. En esta actividad se utiliza aprendizaje supervisado para predecir la variable `left`, donde **1 significa que el empleado dejó la empresa y 0 que permaneció**.

Se utilizará el algoritmo **K Vecinos más Cercanos (KNN)**. Debido a que KNN calcula distancias entre observaciones, las variables numéricas serán estandarizadas antes de entrenar el modelo. Se probarán valores de **K = 1, 2, ..., 20** y se compararán exactitud, precisión, recall, F1 y AUC-ROC.

1. Carga, inspección y recodificación

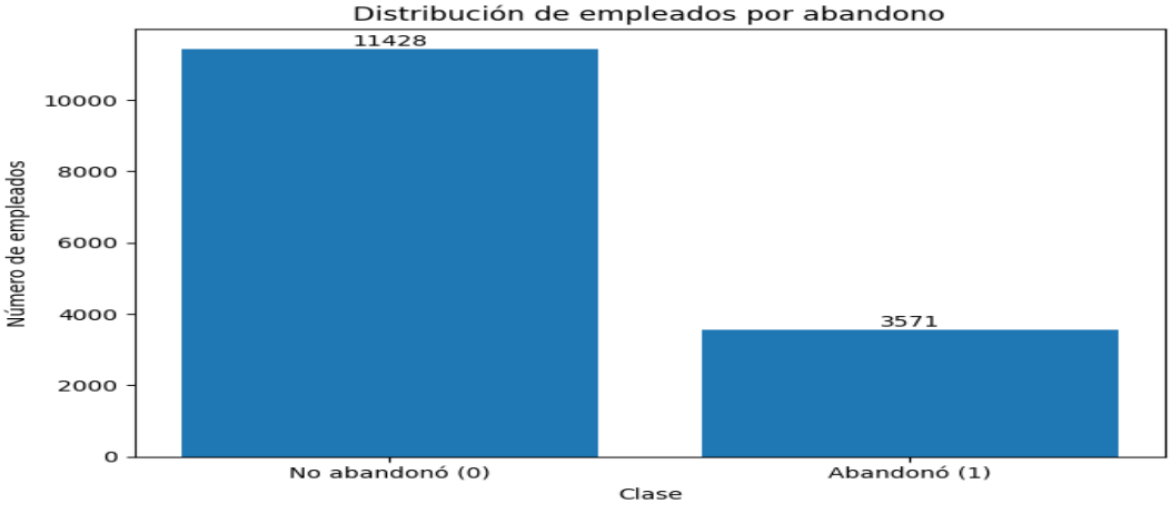
La base contiene 14,999 registros y 10 variables. Las variables categóricas sales y salary se recodificaron mediante pd.get_dummies () para convertirlas en variables numéricas.

```
df=pd.read_csv('recursos_humanos.csv') X = df.drop(columns=['left'])
y = df['left']
X = pd.get_dummies (X, columns=['sales', 'salary'], drop_first=False, dtype=int)
```

2. Balance de clases

Clase	Frecuencia	Porcentaje
0 - No abandonó	11,428	76.19%
1 - Abandonó	3,571	23.81%

La base no está equilibrada: la clase 0 representa 76.19% y la clase 1 solo 23.81%. Por ello no basta con observar accuracy; también se consideran precision, recall, F1 y AUC-ROC.

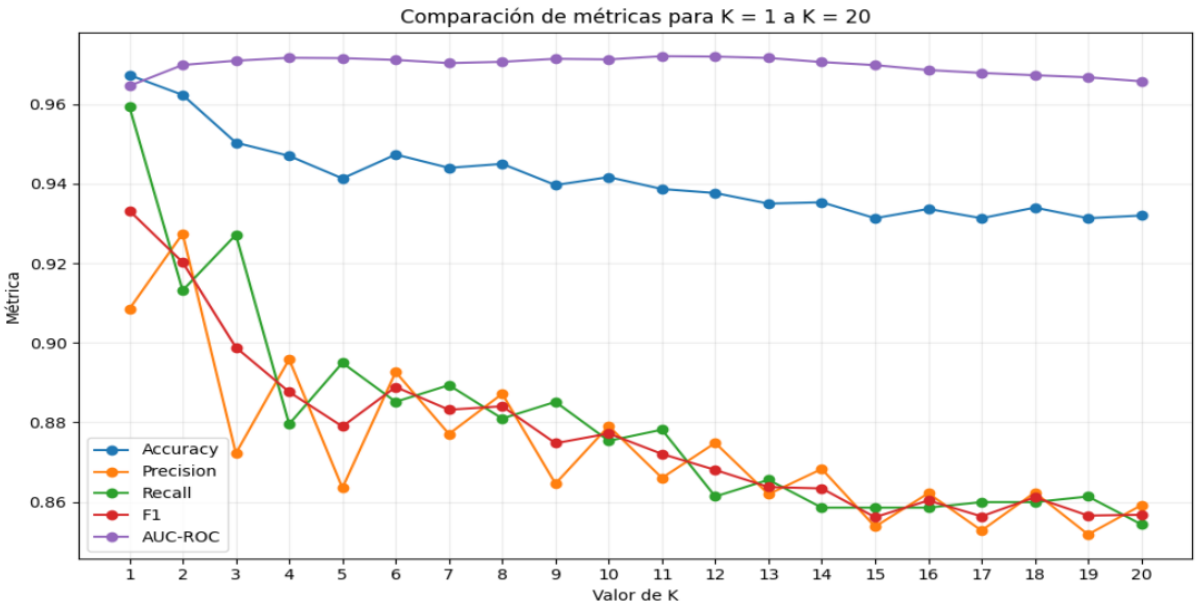

Distribución de empleados por abandono
11428
3571
10000
8000
6000
4000
2000
0
Número de empleados
No abandonó (0)
Abandonó (1)
Clase

3. Modelo KNN y selección de K

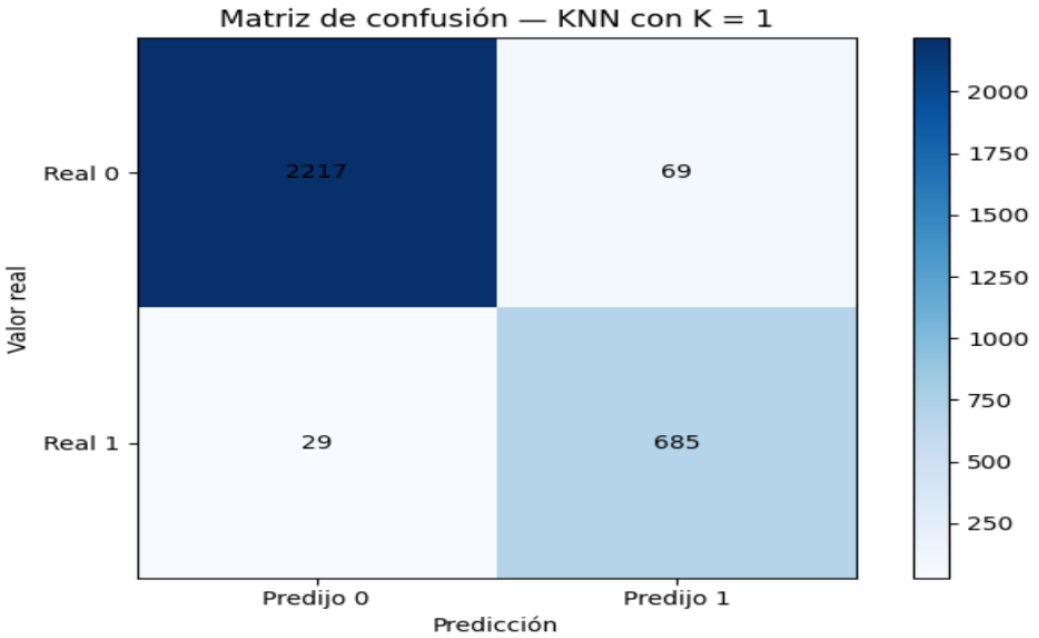
Se dividieron los datos en 80% entrenamiento y 20% prueba, conservando la proporción de clases mediante stratify=y. Después se estandarizaron los predictores con StandardScaler y se evaluaron K=1,20.

K	Accuracy	Precision	Recall	F1	AUC-ROC
1	0.9673	0.9085	0.9594	0.9332	0.9646
2	0.9623	0.9275	0.9132	0.9203	0.9699
3	0.9503	0.8722	0.9272	0.8988	0.9709
4	0.9470	0.8959	0.8796	0.8876	0.9717
5	0.9413	0.8635	0.8950	0.8790	0.9716
6	0.9473	0.8927	0.8852	0.8889	0.9711
7	0.9440	0.8771	0.8894	0.8832	0.9703
8	0.9450	0.8872	0.8810	0.8840	0.9707
9	0.9397	0.8646	0.8852	0.8747	0.9714
10	0.9417	0.8790	0.8754	0.8772	0.9713
11	0.9387	0.8660	0.8782	0.8720	0.9721
12	0.9377	0.8748	0.8613	0.8680	0.9720
13	0.9350	0.8619	0.8655	0.8637	0.9716
14	0.9353	0.8683	0.8585	0.8634	0.9706
15	0.9313	0.8538	0.8585	0.8561	0.9698
16	0.9337	0.8622	0.8585	0.8604	0.9686
17	0.9313	0.8528	0.8599	0.8563	0.9679
18	0.9340	0.8624	0.8599	0.8612	0.9673
19	0.9313	0.8518	0.8613	0.8565	0.9668
20	0.9320	0.8592	0.8543	0.8567	0.9658

Recomendación: K=1. Presenta Accuracy=96.73%, Recall=95.94%, F1=93.32% y Balanced Accuracy=96.46%, el mejor desempeño conjunto para detectar abandonos. K=2 tiene mayor precision (92.75%) y K=11 mayor AUC-ROC (97.21%), pero K=1 favorece el objetivo de reducir falsos negativos.


Comparación de métricas para K = 1 a K = 20
Métrica
Valor de K
Accuracy
Precision
Recall
F1
AUC-ROC
0.96
0.94
0.92
0.90
0.88
0.86
1
2
3
4
5
6
7
8
9
10
11
12
13
14
15
16
17
18
19
20

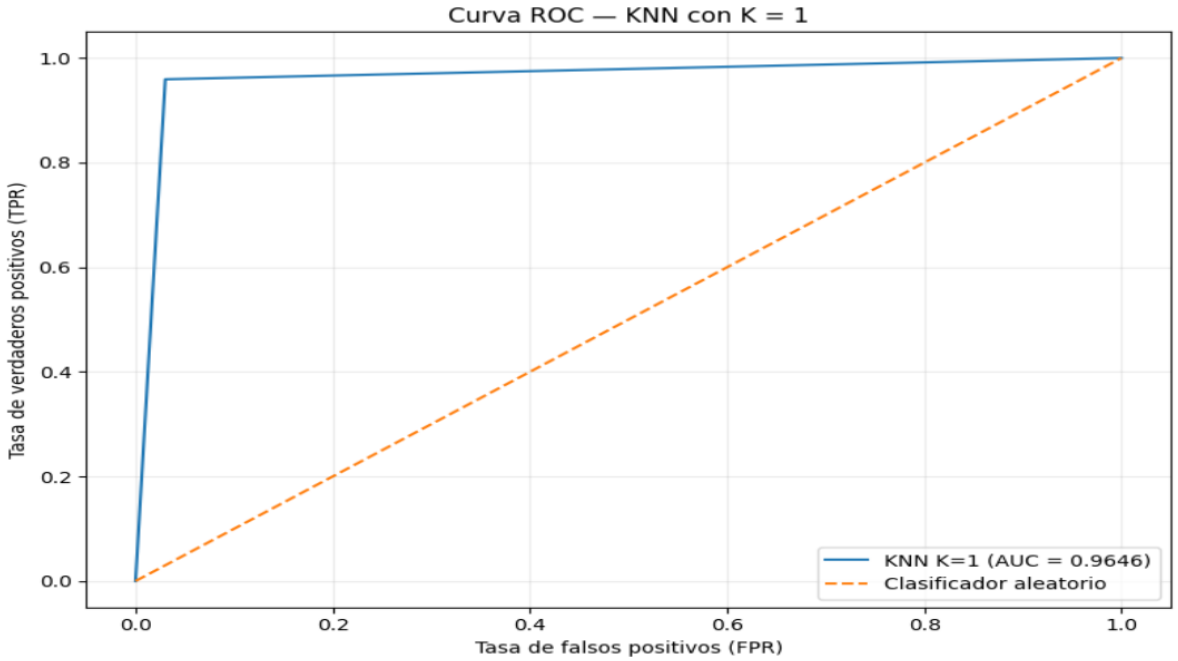
4. Matriz de confusión para K=1



TN=2,217: empleados que permanecieron y fueron clasificados correctamente. FP=69: empleados que permanecieron, pero fueron identificados como posibles desertores. FN=29: empleados que abandonaron, pero no fueron detectados. TP=685: empleados que abandonaron y fueron identificados correctamente.

El modelo detectó 685 de los 714 abandonos reales, equivalente a un recall de 95.94%. El número de falsos negativos es bajo (29), lo cual resulta favorable para un departamento de Recursos Humanos interesado en identificar tempranamente casos de riesgo.

5. Curva ROC



Para K=1, el AUC-ROC es 0.9646. Al estar muy próximo a 1, indica una capacidad excelente para distinguir entre empleados que permanecen y empleados que abandonan. La curva se mantiene claramente por encima de la línea de referencia de un clasificador aleatorio.

6. Conclusiones

La base presenta un desbalance de clases, por lo que la evaluación debe considerar métricas adicionales a la exactitud. La recodificación mediante get_dummies y la estandarización permiten aplicar KNN de forma pertinente. Tras evaluar 20 alternativas, K=1 fue seleccionado por su mejor combinación de recall, F1, accuracy y balanced accuracy. La matriz de confusión muestra 685 verdaderos positivos y únicamente 29 falsos negativos. El AUC de 0.9646 confirma una excelente capacidad de discriminación. En un entorno real, el resultado debería complementarse con validación cruzada y revisión de variables relevantes antes de utilizarlo como apoyo a decisiones de Recursos Humanos.