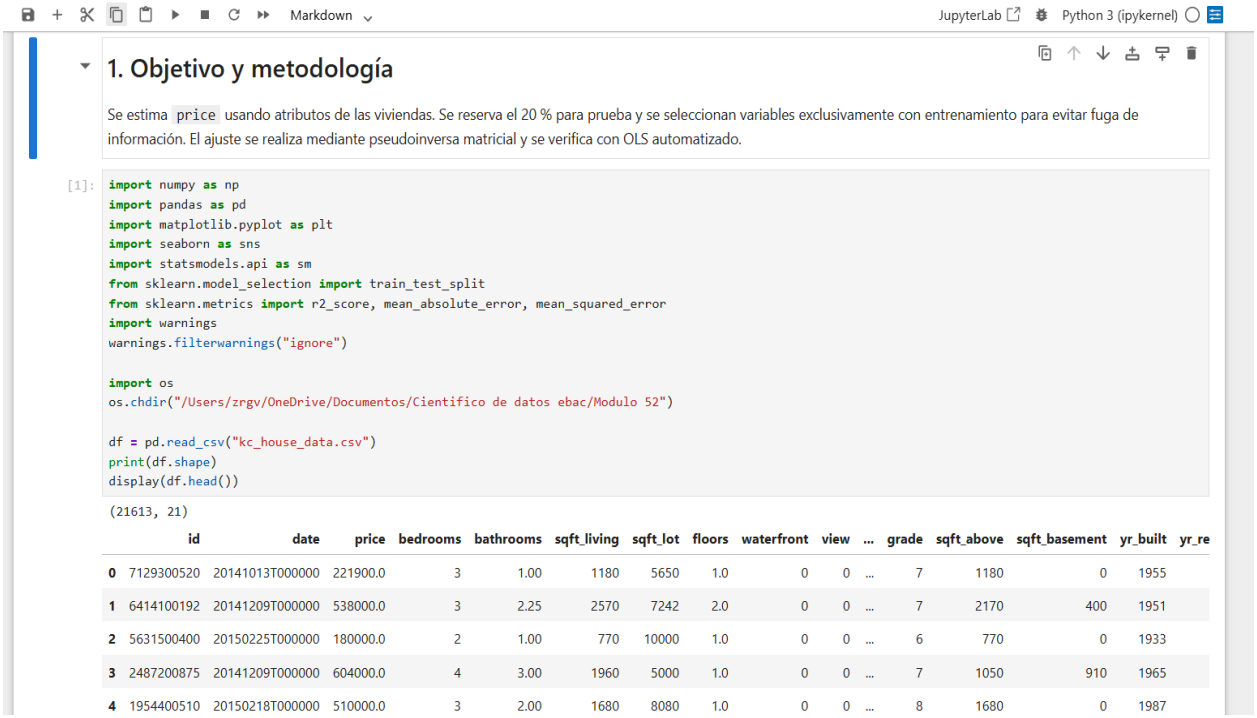
Importación de librerías y carga del archivo csv.



Markdown

JupyterLab Python 3 (ipykernel)

1. Objetivo y metodología

Se estima `price` usando atributos de las viviendas. Se reserva el 20 % para prueba y se seleccionan variables exclusivamente con entrenamiento para evitar fuga de información. El ajuste se realiza mediante pseudoinversa matricial y se verifica con OLS automatizado.

[1]:
```
import numpy as np
import pandas as pd
import matplotlib.pyplot as plt
import seaborn as sns
import statsmodels.api as sm
from sklearn.model_selection import train_test_split
from sklearn.metrics import r2_score, mean_absolute_error, mean_squared_error
import warnings
warnings.filterwarnings("ignore")

import os
os.chdir("/Users/zrgv/OneDrive/Documentos/Cientifico de datos ebac/Modulo 52")

df = pd.read_csv("kc_house_data.csv")
print(df.shape)
display(df.head())
```

```
(21613, 21)
```

	id	date	price	bedrooms	bathrooms	sqft_living	sqft_lot	floors	waterfront	view	...	grade	sqft_above	sqft_basement	yr_built	yr_re
0	7129300520	20141013T000000	221900.0	3	1.00	1180	5650	1.0	0	0	...	7	1180	0	1955	
1	6414100192	20141209T000000	538000.0	3	2.25	2570	7242	2.0	0	0	...	7	2170	400	1951	
2	5631500400	20150225T000000	180000.0	2	1.00	770	10000	1.0	0	0	...	6	770	0	1933	
3	2487200875	20141209T000000	604000.0	4	3.00	1960	5000	1.0	0	0	...	7	1050	910	1965	
4	1954400510	20150218T000000	510000.0	3	2.00	1680	8080	1.0	0	0	...	8	1680	0	1987	

Exploración y limpieza del archivo csv

2. Exploración y limpieza

`id` es un identificador, `date` es una fecha textual y `zipcode` un código categórico, no una cantidad continua. No se incorporan al modelo lineal base. Se inspeccionan valores faltantes y duplicados, sin eliminar observaciones solo por tener el mismo ID.

[2]:
```
display(df.info()); display(df.describe().T); print("Faltantes:",df.isna().sum().sum()); print("Duplicados completos:",df.duplicated().sum())
```

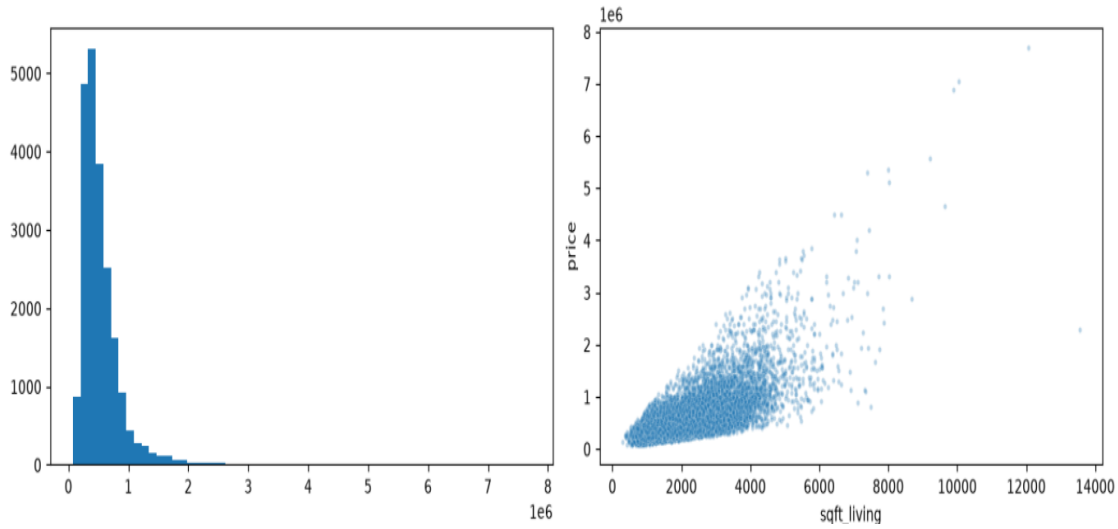
```
<class 'pandas.DataFrame'>
RangeIndex: 21613 entries, 0 to 21612
Data columns (total 21 columns):
 #   Column         Non-Null Count  Dtype
---  ------         --------------  -----
 0   id             21613 non-null  int64
 1   date           21613 non-null  str
 2   price          21613 non-null  float64
 3   bedrooms       21613 non-null  int64
 4   bathrooms      21613 non-null  float64
 5   sqft_living    21613 non-null  int64
 6   sqft_lot       21613 non-null  int64
 7   floors         21613 non-null  float64
 8   waterfront     21613 non-null  int64
 9   view           21613 non-null  int64
 10  condition      21613 non-null  int64
 11  grade          21613 non-null  int64
 12  sqft_above     21613 non-null  int64
 13  sqft_basement  21613 non-null  int64
 14  yr_built       21613 non-null  int64
 15  yr_renovated   21613 non-null  int64
 16  zipcode        21613 non-null  int64
 17  lat            21613 non-null  float64
 18  long           21613 non-null  float64
 19  sqft_living15  21613 non-null  int64
 20  sqft_lot15     21613 non-null  int64
dtypes: float64(5), int64(15), str(1)
```

bedrooms	21613.0	3.370842e+00	9.300618e-01	0.000000e+00	3.000000e+00	3.000000e+00	4.000000e+00	3.300000e+01
bathrooms	21613.0	2.114757e+00	7.701632e-01	0.000000e+00	1.750000e+00	2.250000e+00	2.500000e+00	8.000000e+00
sqft_living	21613.0	2.079900e+03	9.184409e+02	2.900000e+02	1.427000e+03	1.910000e+03	2.550000e+03	1.354000e+04
sqft_lot	21613.0	1.510697e+04	4.142051e+04	5.200000e+02	5.040000e+03	7.618000e+03	1.068800e+04	1.651359e+06
floors	21613.0	1.494309e+00	5.399889e-01	1.000000e+00	1.000000e+00	1.500000e+00	2.000000e+00	3.500000e+00
waterfront	21613.0	7.541757e-03	8.651720e-02	0.000000e+00	0.000000e+00	0.000000e+00	0.000000e+00	1.000000e+00
view	21613.0	2.343034e-01	7.663176e-01	0.000000e+00	0.000000e+00	0.000000e+00	0.000000e+00	4.000000e+00
condition	21613.0	3.409430e+00	6.507430e-01	1.000000e+00	3.000000e+00	3.000000e+00	4.000000e+00	5.000000e+00
grade	21613.0	7.656873e+00	1.175459e+00	1.000000e+00	7.000000e+00	7.000000e+00	8.000000e+00	1.300000e+01
sqft_above	21613.0	1.788391e+03	8.280910e+02	2.900000e+02	1.190000e+03	1.560000e+03	2.210000e+03	9.410000e+03
sqft_basement	21613.0	2.915090e+02	4.425750e+02	0.000000e+00	0.000000e+00	0.000000e+00	5.600000e+02	4.820000e+03
yr_built	21613.0	1.971005e+03	2.937341e+01	1.900000e+03	1.951000e+03	1.975000e+03	1.997000e+03	2.015000e+03
yr_renovated	21613.0	8.440226e+01	4.016792e+02	0.000000e+00	0.000000e+00	0.000000e+00	0.000000e+00	2.015000e+03
zipcode	21613.0	9.807794e+04	5.350503e+01	9.800100e+04	9.803300e+04	9.806500e+04	9.811800e+04	9.819900e+04
lat	21613.0	4.756005e+01	1.385637e-01	4.715590e+01	4.747100e+01	4.757180e+01	4.767800e+01	4.777760e+01
long	21613.0	-1.222139e+02	1.408283e-01	-1.225190e+02	-1.223280e+02	-1.222300e+02	-1.221250e+02	-1.213150e+02
sqft_living15	21613.0	1.986552e+03	6.853913e+02	3.990000e+02	1.490000e+03	1.840000e+03	2.360000e+03	6.210000e+03
sqft_lot15	21613.0	1.276846e+04	2.730418e+04	6.510000e+02	5.100000e+03	7.620000e+03	1.008300e+04	8.712000e+05

```
Faltantes: 0
Duplicados completos: 0
```

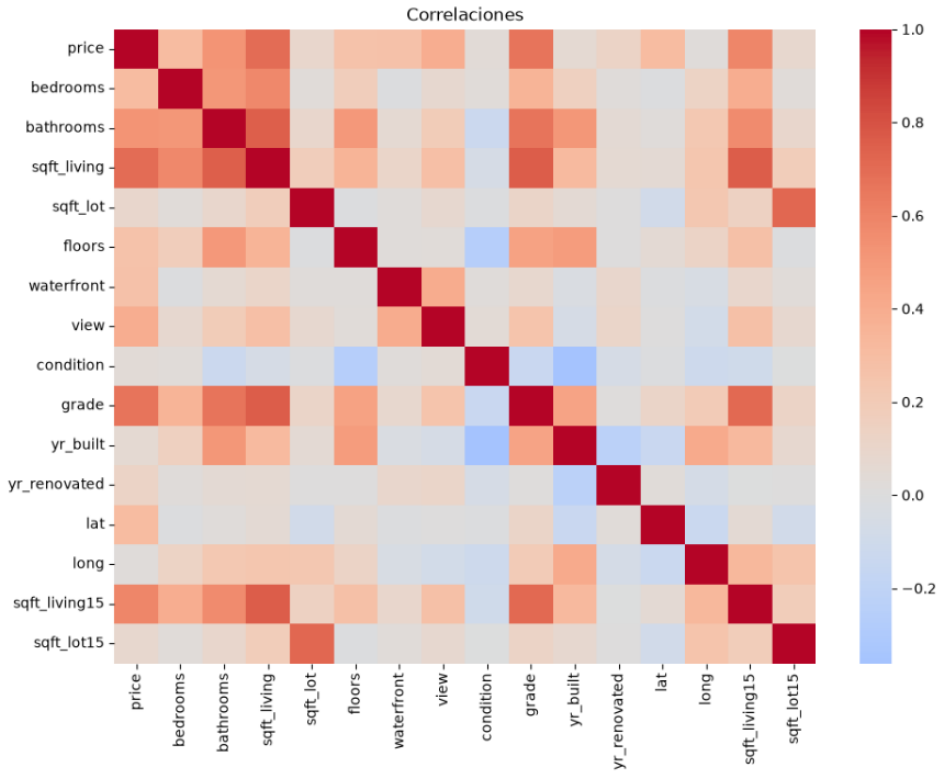
Gráficas de distribución de precios y superficie habitable.

[3]:
```
fig,ax=plt.subplots(1,2,figsize=(13,4)); ax[0].hist(df.price,bins=60);sns.scatterplot(data=df,x="sqft_living",y="price",s=8,alpha=.3,ax=ax[1]);
plt.tight_layout();plt.show()
```



Matriz de correlaciones

```
[4]: features = ['bedrooms', 'bathrooms', 'sqft_living', 'sqft_lot', 'floors', 'waterfront', 'view', 'condition', 'grade', 'yr_built', 'yr_renovated', 'lat'
plt.figure(figsize=(11,8));sns.heatmap(df[["price"]+features].corr(),cmap="coolwarm",center=0);plt.title("Correlaciones");plt.show()
```



Formulación de la matriz

3. Formulación matricial

Para una matriz de diseño X que incluye una columna de unos, $y = X\beta + \varepsilon$. Los mínimos cuadrados minimizan $\|y - X\beta\|_2^2$. Las ecuaciones normales son $X^T X\hat{\beta} = X^T y$. Si existe inversa, $\hat{\beta} = (X^T X)^{-1} X^T y$. **En la práctica se utiliza** $\hat{\beta} = X^+ y$ mediante `np.linalg.pinv`, más robusta ante singularidad o multicolinealidad.

```
[5]: X_train, X_test, y_train, y_test = train_test_split(df[features],df["price"],test_size=0.20,random_state=42)
print("Entrenamiento:",len(X_train),"Prueba:",len(X_test))
```

```
Entrenamiento: 17290 Prueba: 4323
```

Selección de variables.

4. Selección de variables

Se aplica eliminación hacia atrás por significancia (umbral p < 0.05) **solo en entrenamiento**. Es una selección exploratoria, no una garantía causal ni de óptima generalización. Los p-valores posteriores a selección deben interpretarse con cautela. Variables correlacionadas pueden afectar la estabilidad de los coeficientes.

```
selected=features.copy(); history=[]
while True:
    temp=sm.OLS(y_train,sm.add_constant(X_train[selected],has_constant="add")).fit()
    p=temp.pvalues.drop("const",errors="ignore")
    worst=p.idxmax(); history.append({"variable":worst,"p_value":float(p.max()),"variables_restantes":len(selected)})
    if p.max() <= 0.05: break
    selected.remove(worst)
print("Variables finales:",selected)
display(pd.DataFrame(history))
```

```
Variables finales: ['bedrooms', 'bathrooms', 'sqft_living', 'floors', 'waterfront', 'view', 'condition', 'grade', 'yr_built', 'yr_renovated', 'lat', 'long', 'sqft_living15', 'sqft_lot15']
```

	variable	p_value	variables_restantes
0	sqft_lot	0.107041	15
1	floors	0.000227	14

Estimación matricial y reporte automatizado

5. Estimación matricial explícita y reporte automatizado

```
A_train=sm.add_constant(X_train[selected],has_constant="add").to_numpy(); A_test=sm.add_constant(X_test[selected],has_constant="add").to_numpy()
beta=np.linalg.pinv(A_train)@y_train.to_numpy()
modelo=sm.OLS(y_train,sm.add_constant(X_train[selected],has_constant="add")).fit()
comparacion=pd.DataFrame({"variable":["intercepto"]+selected,"beta_matricial":beta,"beta_statsmodels":modelo.params.values,"p_valor":modelo.pvalues.valu
display(comparacion);print(modelo.summary())
```

	variable	beta_matricial	beta_statsmodels	p_valor
0	intercepto	-3.159715e+07	-3.159715e+07	9.542371e-75
1	bedrooms	-3.307805e+04	-3.307805e+04	1.079231e-55
2	bathrooms	4.173000e+04	4.173000e+04	4.307697e-31
3	sqft_living	1.667711e+02	1.667711e+02	0.000000e+00
4	floors	1.316124e+04	1.316124e+04	2.272484e-04
5	waterfront	5.725708e+05	5.725708e+05	3.189733e-182
6	view	4.792585e+04	4.792585e+04	2.064916e-92
7	condition	2.729336e+04	2.729336e+04	5.823895e-26
8	grade	9.810219e+04	9.810219e+04	0.000000e+00
9	yr_built	-2.546809e+03	-2.546809e+03	3.149435e-215
10	yr_renovated	2.165312e+01	2.165312e+01	1.228805e-07

```
                            OLS Regression Results
==============================================================================
Dep. Variable:                  price   R-squared:                       0.694
Model:                            OLS   Adj. R-squared:                  0.694
Method:                 Least Squares   F-statistic:                     2802.
Date:                Wed, 21 Oct 2026   Prob (F-statistic):               0.00
Time:                        11:50:40   Log-Likelihood:            -2.3556e+05
No. Observations:               17290   AIC:                         4.712e+05
Df Residuals:                   17275   BIC:                         4.713e+05
Df Model:                          14
Covariance Type:            nonrobust
==============================================================================
                 coef    std err          t      P>|t|      [0.025      0.975]
------------------------------------------------------------------------------
const      -3.16e+07   1.72e+06    -18.381      0.000    -3.5e+07   -2.82e+07
bedrooms   -3.308e+04   2096.463    -15.778      0.000   -3.72e+04    -2.9e+04
bathrooms   4.173e+04   3591.539     11.619      0.000    3.47e+04    4.88e+04
sqft_living   166.7711      3.739     44.606      0.000     159.443     174.100
floors      1.316e+04   3569.243      3.687      0.000    6165.159    2.02e+04
waterfront  5.726e+05   1.97e+04     29.135      0.000    5.34e+05    6.11e+05
view        4.793e+04   2336.334     20.513      0.000    4.33e+04    5.25e+04
condition   2.729e+04   2586.006     10.554      0.000    2.22e+04    3.24e+04
grade        9.81e+04   2364.978     41.481      0.000    9.35e+04    1.03e+05
yr_built   -2546.8086     80.183    -31.763      0.000   -2703.975   -2389.643
yr_renovated    21.6531      4.092      5.291      0.000      13.632      29.674
lat         5.459e+05   1.16e+04     47.198      0.000    5.23e+05    5.69e+05
long       -8.127e+04    1.3e+04     -6.244      0.000   -1.07e+05   -5.58e+04
sqft_living15    30.0372      3.779      7.948      0.000      22.630      37.445
sqft_lot15      -0.2266      0.058     -3.888      0.000      -0.341      -0.112
==============================================================================
Omnibus:                    15215.257   Durbin-Watson:                   1.997
Prob(Omnibus):                  0.000   Jarque-Bera (JB):          1773963.542
Skew:                           3.726   Prob(JB):                         0.00
Kurtosis:                      52.060   Cond. No.                     3.43e+07
==============================================================================
```

Ecuación final e interpretación.

6. Ecuación final e interpretación

Cada coeficiente representa el cambio esperado en USD al incrementar una unidad de su variable, manteniendo las demás constantes. Las variables `waterfront`, `view`, `condition` y `grade` se tratan numéricamente en este modelo base: ello impone una estructura lineal que conviene examinar.

[8]:
```
ecuacion=f"precio_estimado = {beta[0]:,.4f}"
for v,b in zip(selected,beta[1:]): ecuacion+=f" {b:+,.4f}*{v}"
print(ecuacion)
```

```
precio_estimado = -31,597,153.8432 -33,078.0502*bedrooms +41,729.9985*bathrooms +166.7711*sqft_living +13,161.2359*floors +572,570.8048*waterfront +47,
925.8463*view +27,293.3611*condition +98,102.1946*grade -2,546.8086*yr_built +21.6531*yr_renovated +545,875.5969*lat -81,274.7890*long +30.0372*sqft_li
ving15 -0.2266*sqft_lot15
```

Bondad de ajuste y validación fuera de muestra.

7. Bondad de ajuste y validación fuera de muestra

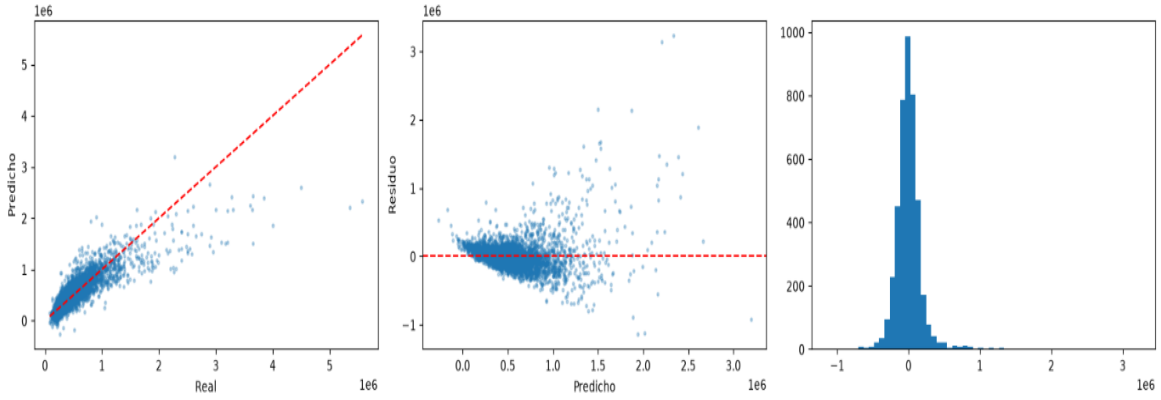
El R^2 indica la fracción de variación explicada, el R^2 ajustado penaliza predictores, y MAE/RMSE cuantifican errores en USD. El conjunto de prueba no participa en selección ni ajuste.

[9]:
```
y_pred=A_test@beta; y_pred_auto=modelo.predict(sm.add_constant(X_test[selected],has_constant="add"))
metricas=pd.Series({"R2_entrenamiento":r2_score(y_train,A_train@beta),"R2_ajustado_entrenamiento":modelo.rsquared_adj,"R2_prueba":r2_score(y_test,y_pred
display(metricas.to_frame("valor"))
```

	valor
R2_entrenamiento	0.694261
R2_ajustado_entrenamiento	0.694013
R2_prueba	0.694658
MAE_prueba_USD	128195.576268
RMSE_prueba_USD	214850.209668
diferencia_maxima_metodos	0.000000

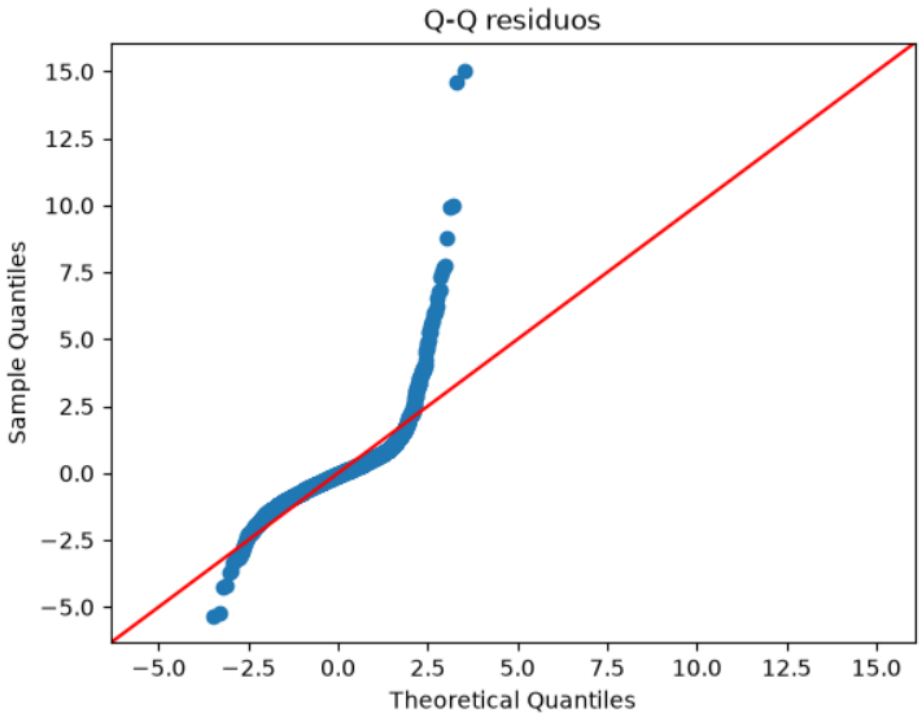
Predicciones, Residuos e Histograma de residuos

]:
```
residuos=y_test.to_numpy()-y_pred
fig,axs=plt.subplots(1,3,figsize=(17,4));axs[0].scatter(y_test,y_pred,s=5,alpha=.3);
axs[0].plot([y_test.min(),y_test.max()],[y_test.min(),y_test.max()],"r--");axs[0].set(xlabel="Real",ylabel="Predicho");
axs[1].scatter(y_pred,residuos,s=5,alpha=.3);axs[1].axhline(0,color="r",ls="--");axs[1].set(xlabel="Predicho",ylabel="Residuo");
axs[2].hist(residuos,bins=60);plt.tight_layout();
plt.show()
```



Gráfica Q-Q residuos

[11]:
```
fig=sm.qqplot(residuos,line="45",fit=True);plt.title("Q-Q residuos");plt.show()
print("Condición de X:",np.linalg.cond(A_train))
```




```
Condición de X: 34329273.815590814
```

Conclusiones

8. Conclusiones

El método matricial por pseudoinversa y Statsmodels deben producir estimaciones equivalentes dentro de tolerancias numéricas. El rendimiento debe juzgarse prioritariamente con R^2, MAE y RMSE de prueba. La correlación entre superficie, calidad y otras variables, la heterocedasticidad y los valores extremos limitan la interpretación causal y pueden deteriorar las predicciones. Una mejora posterior sería codificar las variables ordinales/categóricas, explorar transformaciones de precio, regularización y validación cruzada.

]:
```
print("Variables retenidas:",", ".join(selected)); print("R² prueba:",round(metricas["R2_prueba"],4)); print("RMSE USD:",round(metricas["RMSE_prueba_USD
comparacion.to_csv("coeficientes_regresion.csv",index=False);metricas.to_csv("metricas_regresion.csv");print("Archivos CSV exportados")
```

```
Variables retenidas: bedrooms, bathrooms, sqft_living, floors, waterfront, view, condition, grade, yr_built, yr_renovated, lat, long, sqft_living15, sq
ft_lot15
R² prueba: 0.6947
RMSE USD: 214850.21
Archivos CSV exportados
```