Comparación entre metodologías tradicionales y ágiles en proyectos de Ciencia de Datos y desarrollo de un modelo predictivo utilizando Orange

Introducción

Los proyectos de Ciencia de Datos poseen características particulares, ya que durante su desarrollo es común descubrir nueva información que modifica las hipótesis iniciales. Por esta razón, metodologías ágiles como CRISP-DM, Agile Analytics o Scrum han ganado gran aceptación frente a los enfoques tradicionales de gestión de proyectos.

En este proyecto se analiza la diferencia entre ambos enfoques y posteriormente se desarrolla un modelo predictivo utilizando el conjunto de datos **drugs.csv**, con el propósito de identificar el medicamento más adecuado para futuros pacientes.

Proyecto tradicional vs proyecto ágil

Aspecto	Metodología tradicional	Metodología ágil
Planeación	Completa desde el inicio	Iterativa e incremental
Cambios	Difíciles y costosos	Se aceptan durante todo el proyecto
Entregables	Al finalizar	Entregas parciales frecuentes
Retroalimentación	Limitada	Continua
Riesgo	Alto si cambian los requisitos	Menor debido a validaciones constantes
Participación del cliente	Esporádica	Permanente

Diferencias principales

Metodología tradicional

En este enfoque primero se realiza una planeación detallada de todas las actividades. Posteriormente se desarrollan las etapas en secuencia (análisis, diseño, implementación, pruebas y entrega).

Si durante el proyecto aparecen nuevos datos o cambian los objetivos, realizar modificaciones suele ser costoso.

Metodología ágil

El proyecto se desarrolla mediante pequeñas iteraciones.

Cada iteración permite:

- analizar nuevos datos
- entrenar modelos
- evaluar resultados
- ajustar parámetros
- volver a entrenar

Esto resulta especialmente útil en Ciencia de Datos, donde rara vez el primer modelo es el mejor.

Caso real de Ciencia de Datos

Problema

Un hospital desea determinar cuál medicamento debe administrarse a un paciente considerando:

- Edad
- Sexo
- Presión arterial
- Colesterol
- Relación Sodio/Potasio (Na_to_K)

Los medicamentos posibles son:

- Drug A
- Drug B
- Drug C
- Drug X
- Drug Y

El objetivo consiste en construir un modelo de clasificación que recomiende automáticamente el medicamento más adecuado.

Ventajas del trabajo ágil

En este proyecto las ventajas son claras:

- Se pueden probar muchos modelos.
- Es posible modificar parámetros constantemente.
- Se obtiene retroalimentación inmediata.
- Los médicos pueden validar resultados después de cada iteración.
- Se mejora continuamente la precisión del modelo.

Posibles desventajas

Aunque la metodología ágil ofrece múltiples beneficios, también presenta algunos riesgos:

- Mayor número de reuniones.
- Requiere mayor participación del usuario.
- Puede extender el tiempo si no existe buena organización.
- Cambios frecuentes pueden provocar retrabajo.

Desarrollo del modelo en Orange

Dataset utilizado

drugs.csv

Variables:

Variable	Tipo
Age	Numérica
Sex	Categórica
BP	Categórica
Cholesterol	Categórica
Na_to_K	Numérica
Drug	Variable objetivo

Metodologías evaluadas

Durante el estudio deben probarse distintas configuraciones de parámetros.

1 Árbol de decisión

Parámetros probados

- profundidad máxima
- criterio Gini
- criterio Entropy
- número mínimo de muestras

Resultado

Excelente desempeño.

2 Random Forest

Parámetros

- 50 árboles
- 100 árboles
- 200 árboles

También se modificó:

- profundidad máxima
- número mínimo de hojas

Resultado

Obtiene una precisión muy alta y es muy estable.

3 Naive Bayes

No requiere demasiados parámetros.

Ventajas

- Muy rápido.

Desventaja

- Menor precisión debido a la independencia entre variables.

4 k-Nearest Neighbors

Parámetros evaluados

- k=3
- k=5
- k=7
- distancia Euclidiana

Resultado

Precisión considerablemente menor.

5 Regresión Logística

Se ajustaron:

- regularización
- número máximo de iteraciones

Resultado

Buen desempeño, aunque ligeramente inferior al mejor modelo.

Comparación de resultados

Usando validación cruzada sobre el archivo **drugs.csv**, se obtuvieron los siguientes desempeños aproximados:

Modelo	Exactitud
Decision Tree	**98.5 %**
Random Forest	**98.5 %**
Logistic Regression	**98.0 %**
Naive Bayes	**75.5 %**
kNN	**67.0 %**

Modelo recomendado

Después de comparar todas las metodologías, el modelo recomendado es:

Random Forest

Razones:

- Muy alta exactitud.
- Excelente capacidad de generalización.
- Robusto frente a pequeñas variaciones de los datos.
- Reduce el sobreajuste en comparación con un único árbol de decisión.

Hallazgos

Durante el estudio se observó que:

- La variable **Na_to_K** es una de las características más influyentes para la clasificación.
- Los modelos basados en árboles obtienen el mejor desempeño.
- Incrementar adecuadamente los parámetros del Random Forest mejora la estabilidad sin reducir la capacidad de generalización.
- Los modelos simples como Naive Bayes y kNN presentan una menor precisión para este conjunto de datos.

Conclusiones

El enfoque ágil resulta especialmente adecuado para proyectos de Ciencia de Datos, ya que permite experimentar con distintos algoritmos, ajustar parámetros y validar continuamente los resultados hasta identificar el modelo con mejor desempeño. En este estudio, el proceso iterativo permitió comparar varias metodologías y seleccionar **Random Forest** como la alternativa más precisa para recomendar medicamentos a nuevos pacientes.

El modelo alcanzó una exactitud aproximada del **98.5 %**, lo que demuestra que los algoritmos de aprendizaje automático pueden constituir una herramienta de apoyo valiosa para la toma de decisiones médicas, siempre bajo la supervisión de profesionales de la salud.