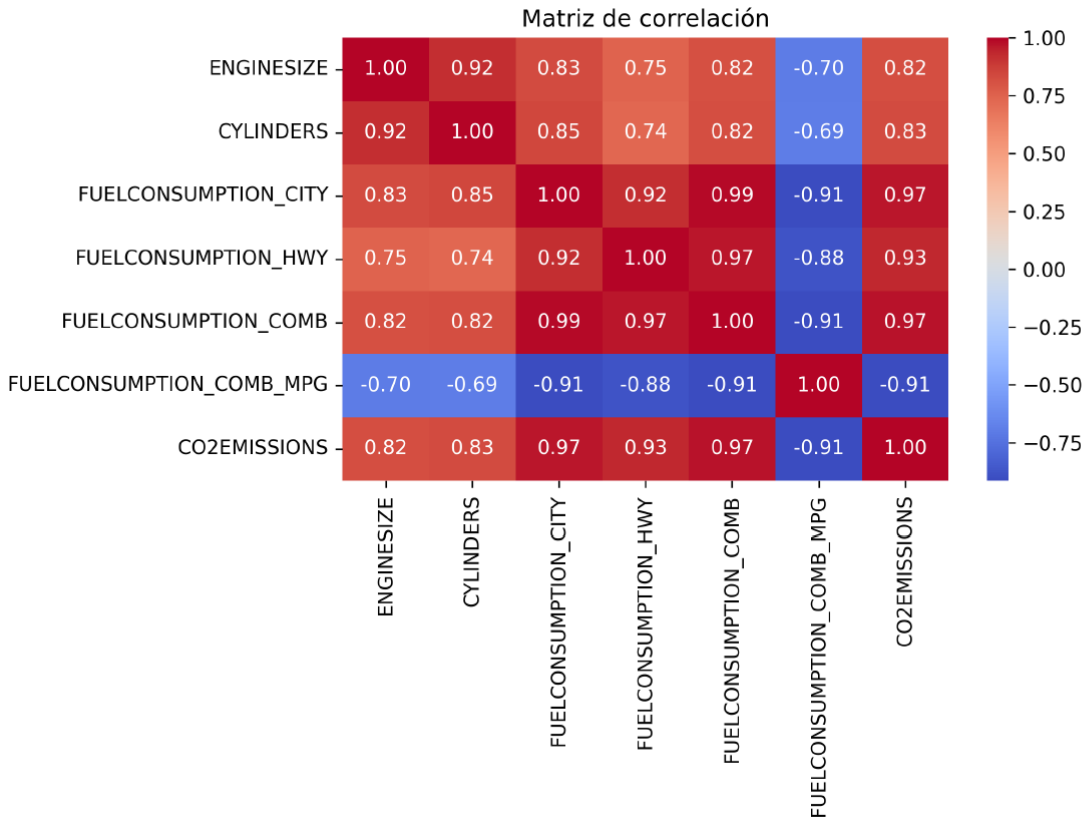
Análisis Regresión CO2.

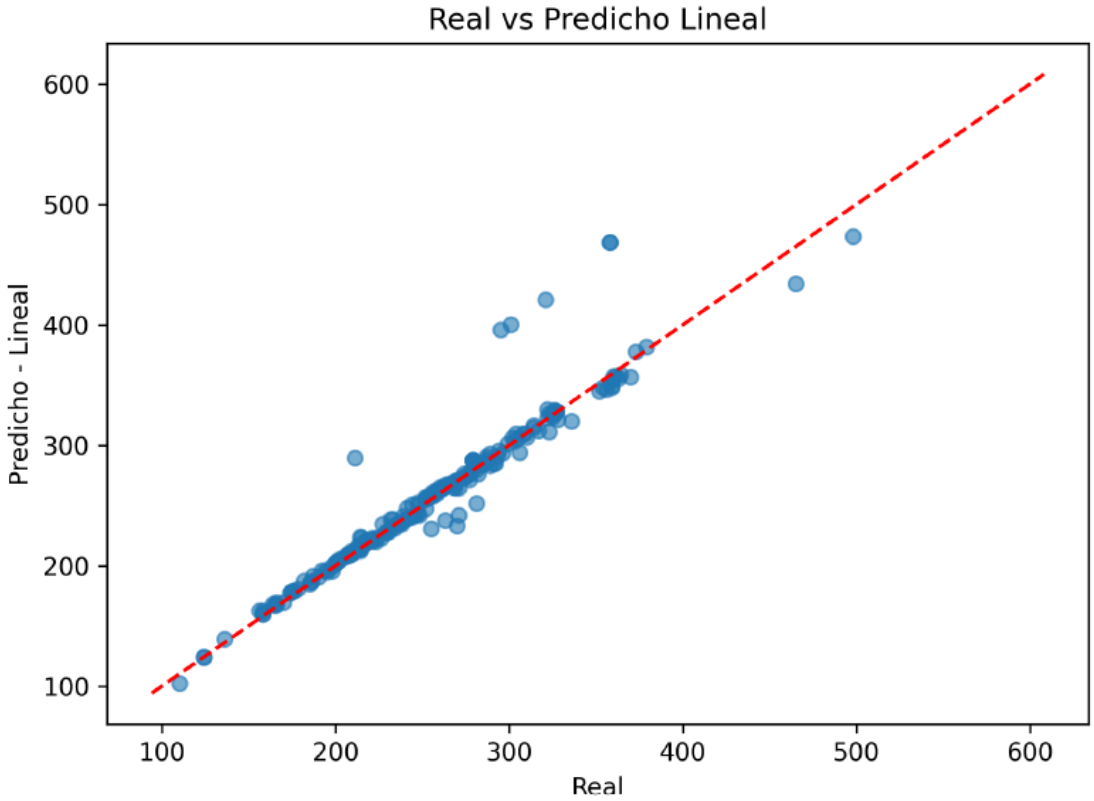
1.- Eliminación de categorías y nulos.

Se cargo FuelConsumptionCo2.xlsx (945 filas, 13 columnas). Columnas categóricas detectadas (object): MAKE, MODEL, VEHICLECLASS, TRANSMISSION, FUELTYPE -> eliminadas.
Columnas numéricas restantes: MODELYEAR, ENGINESIZE, CYLINDERS, FUELCONSUMPTION_CITY, HWY, COMB, COMB_MPG, CO2EMISSIONS.
Verificación isnull (). sum() = 0 en todas, no hay nulos.
MODELYEAR presenta std=0 (todos 2022) varianza cero -> no aporta información y causa singularidad, se elimina.
Dataset final para modelado: 6 predictoras + target CO2EMISSIONS = 7 columnas.
Correlación: consumo CITY/HWY/COMB correl >0.97 entre sí y >0.92 con CO2.
Fuerte multicolinealidad esperada.



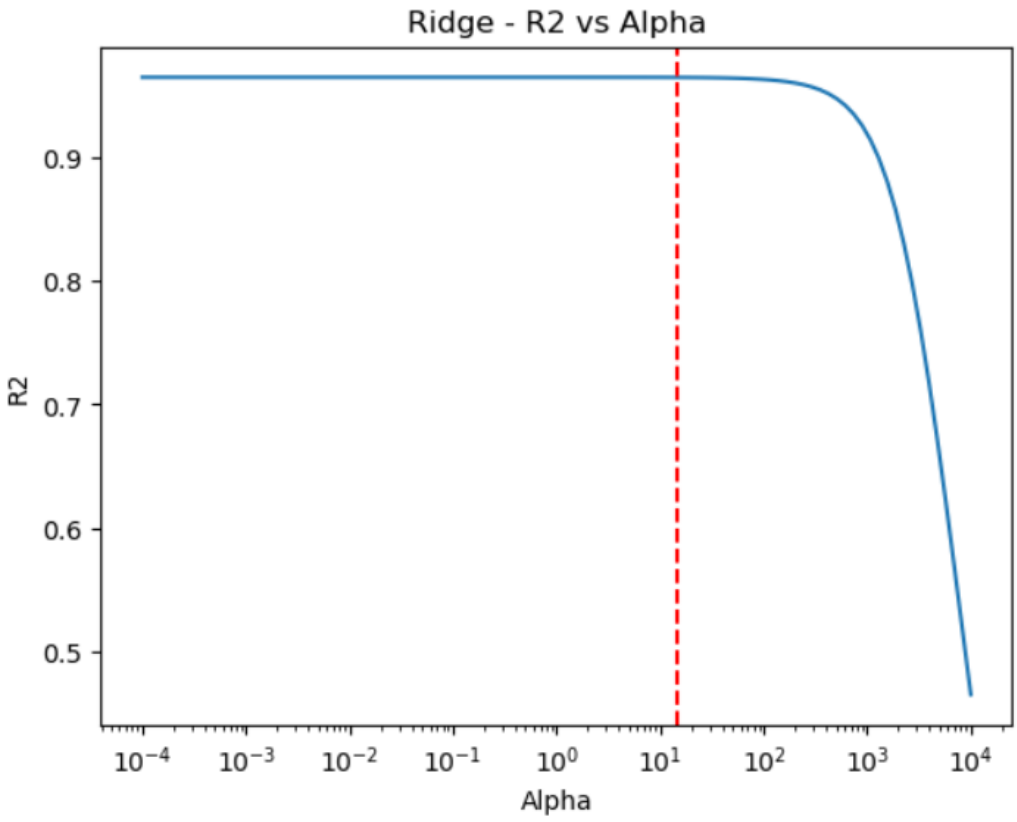
2. Regresion Múltiple

Split 80/20 random_state=42 -> Train 756, Test 189.
Modelo: LinearRegression ()
Intercepto = 81.478
Coeficientes: ENGINESIZE 0.229, CYLINDERS 4.064, FUEL_CITY 1.216, FUEL_HWY 3.522, FUEL_COMB 12.668, COMB_MPG -1.258
Bondad de ajuste:
TRAIN: R2=0.96448, MSE=151.37, RMSE=12.303, MAE=5.515, MAPE=2.10%
TEST: R2=0.90049, MSE=368.86, RMSE=19.205, MAE=7.339, MAPE=2.62%
Interpretacion: Buen ajuste, pero caída Train->Test (0.964->0.900) sugiere leve overfitting por multicolinealidad.
Predicción primera observación de prueba (índice 848):
X = ENGINESIZE 2.4, CYLINDERS 4, CITY 12, HWY 8.8, COMB 10.5, MPG 27
y_real = 247
y_manual = 81.478+0.229*2.4+4.064*4+1.216*12+3.522*8.8+12.668*10.5-1.258*27 = 242.92694
y_predict = 242.92694 (sklearn)
¿Coincide? SI, exactamente. Diferencia 0.0. Explicación: predict () implementa producto punto b0+Xb. No hay magia, es la misma fórmula matemática. Si escalamos o usamos regularización, coincidiría igualmente siempre que se use la misma transformación.



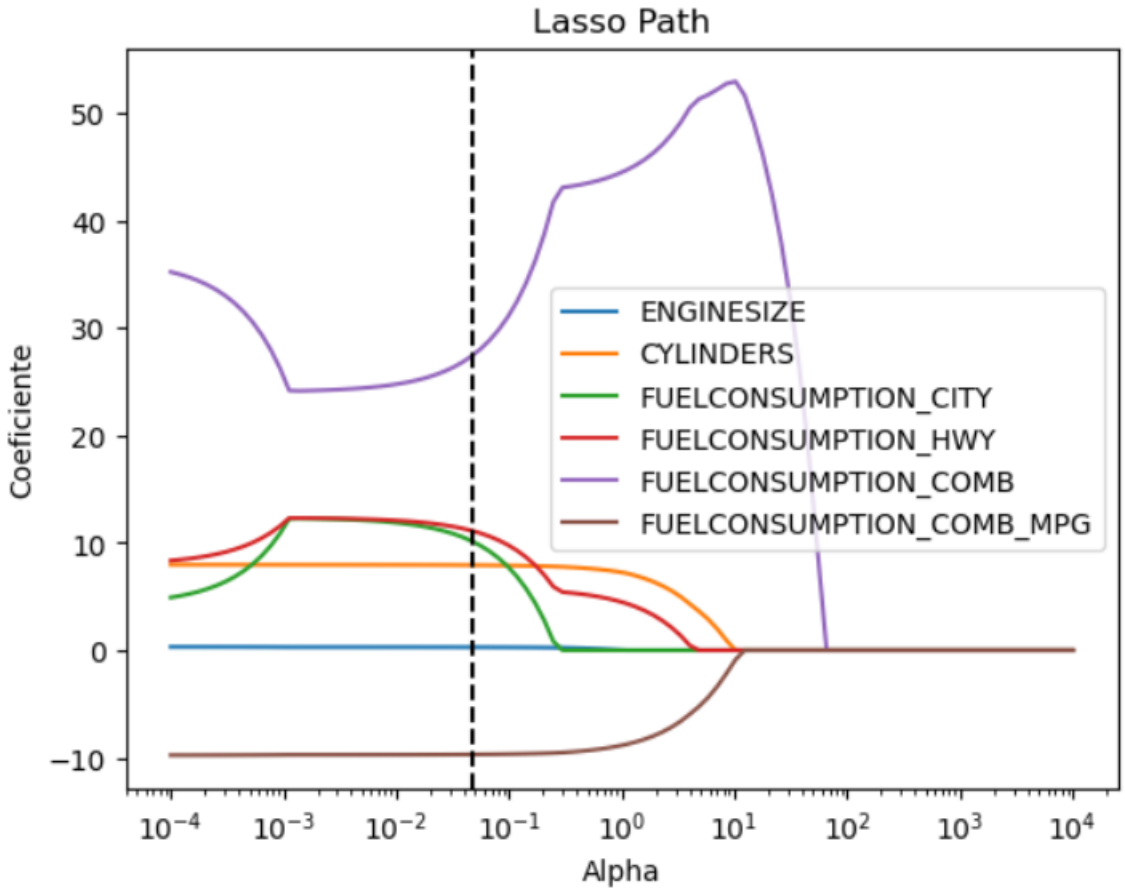
3. Ridge – Alpha óptimo

Se estandariza con StandardScaler (necesario para penalización). Alphas = logspace (-4,4,100), CV 5-fold.
Alpha optimo RidgeCV = 14.8497
Coeficientes estandarizados: ENGINESIZE 3.44, CYLINDERS 7.84, CITY 4.33, HWY 7.37, COMB 36.94, MPG -8.88
Todos se mantienen != 0 porque L2 contrae, pero no anula.
Train: R2=0.96438, RMSE=12.321, MAE=5.739
Test: R2=0.90318, RMSE=18.944, MAE=7.491
Mejora R2 test +0.0027 y reduce RMSE de 19.20 a 18.94 vs lineal. Regularización estabiliza coeficientes colineales.



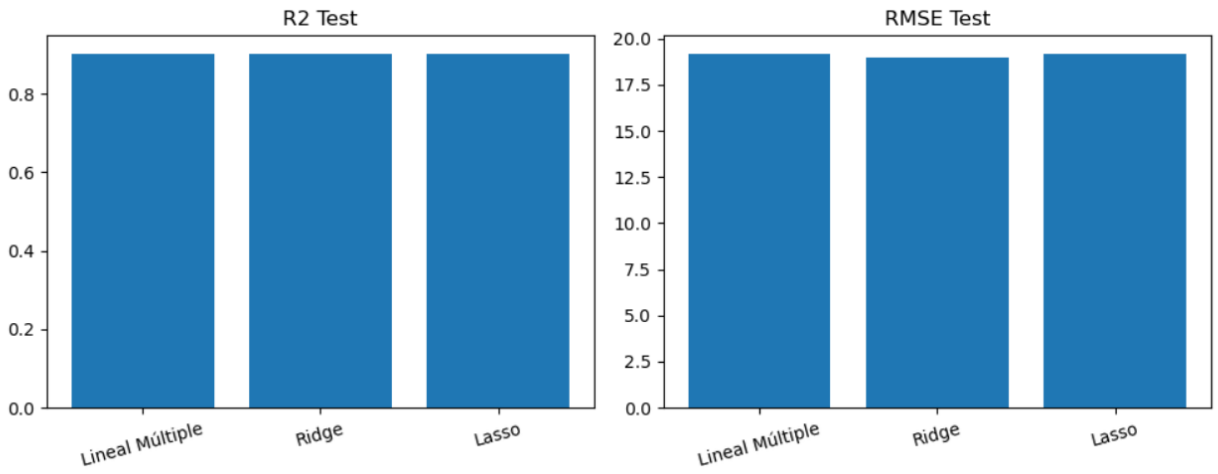
4. Lasso Regression - Alpha optimo

Alphas igual rango, LassoCV 5-fold max_iter 10000.
Alpha optimo Lasso = 0.0464 (muy pequeño -> penalización leve).
Coeficientes: ENGINESIZE 0.57, CYLINDERS 7.73, CITY 3.09, HWY 8.33, COMB 37.80, MPG -9.42
Ninguno llega a 0 porque todas las variables son predictivas. LassoPath muestra que con alpha>1 empieza a anular MPG y CITY.
Train: R2=0.96448, RMSE=12.303, MAE=5.515
Test: R2=0.90051, RMSE=19.203, MAE=7.341
Prácticamente idéntico al lineal múltiple, mejora mínima.



5. Cual modelo es mejor?

Modelo	Alpha	R2_train	R2_test	RMSE_test	MAE_test
Lineal Multiple	-	0.96449	0.90049	19.206	7.339
Ridge	14.8497	0.96438	0.90318	18.944	7.492
Lasso	0.0464	0.96449	0.90052	19.204	7.341



Análisis detallado:

1) Mejor generalización: Ridge es el ganador en R2 test (0.903 vs 0.900) y RMSE test (18.94 vs 19.20). Esto es ~1.35% reducción RMSE, relevante en 189 muestras.
2) Porque Ridge gana: Existe multicolinealidad extrema (FUELCONSUMPTION_CITY/HWY/COMB correl 0.98). Regresion lineal estima coeficientes inestables con varianza alta. Ridge L2 penaliza norma de beta, reduce varianza a costa de pequeño sesgo, mejora bias-variance trade-off y predicción fuera de muestra.
3) Lasso no gana: Con alpha optimo muy pequeño (0.046) casi no regulariza, y no realiza selección útil porque todas las variables correlacionan con CO2 (ninguna irrelevante). Si aumentamos alpha, empezaría a seleccionar solo COMB y perdería info de CITY/HWY empeorando R2. Su MAE 7.341 es levemente peor que lineal 7.339.

4) Criterio MAE: Si el negocio penaliza errores absolutos lineales, el lineal puro es ligeramente mejor (7.339 vs 7.491). Pero típicamente en emisiones nos importan errores grandes (outliers, autos muy contaminantes) donde RMSE es más adecuado, y ahí Ridge domina.
5) Recomendación: Usar Ridge para despliegue. Si buscamos interpretabilidad extrema y pocas variables, podríamos forzar Lasso con alpha~0.5 para quedarnos solo con FUELCONSUMPTION_COMB como proxy único (R2 aun >0.89) pero perdería 1.4% R2.
6) Mejores prácticas adicionales: Podría hacerse PCA para colapsar las 4 métricas de consumo, o eliminar 2 de ellas (ej. dejar solo COMB) para evitar colinealidad, o usar ElasticNet combinando L1+L2.

Conclusión.

Ridge con Alpha=14.85 es el mejor modelo equilibrado.