RESUMEN EJECUTIVO DEL ANÁLISIS DE CLUSTERING JERÁRQUICO

Metodología Aplicada

Se realizó un **Clustering Jerárquico Aglomerativo** con el método de Ward sobre 100 clientes de Amazon, utilizando 9 variables de evaluación. Los datos fueron estandarizados previamente. El número óptimo de clusters determinado fue **k=5** (Silhouette Score = 0.1067), lo cual genera segmentos interpretables para el negocio.

VERIFICACIÓN DE LIMPIEZA DE DATOS (PRE-MODELADO)

Antes de estandarizar las variables y aplicar el clustering, se realizó una revisión exhaustiva del dataset original:

1.1 Valores Nulos (Missing Values)

Variable	Valores Nulos	Porcentaje
Todas las 9 variables	**0**	**0.0%**

Conclusión: El dataset no contiene valores nulos. Todas las 100 filas y 9 columnas están completas.

Registros Duplicados

Tipo de duplicado	Cantidad
Filas completamente idénticas	**0**
Nombres de clientes duplicados	**0**
Clientes únicos	**100 de 100**

Conclusión: No hay registros duplicados. Cada cliente tiene un nombre único y un perfil de evaluaciones distinto.

Detección de Outliers (Método IQR)

Variable	Q1	Q3	IQR	Límite Inferior	Límite Superior	Outliers Detectados	% Outliers
Velocidad_Entrega	15.0	167.5	152.5	-213.8	396.3	0	0.0%
Precio	9.0	95.0	86.0	-120.0	224.0	2	2.0%
Durabilidad	41.0	417.5	376.5	-523.8	982.3	0	0.0%
Imagen_Producto	25.0	245.0	220.0	-305.0	575.0	0	0.0%
Valor_Educativo	21.0	34.0	13.0	1.5	53.5	0	0.0%
Servicio_Retorno	19.0	28.0	9.0	5.5	41.5	**13**	**13.0%**
Tamano_Paquete	32.5	320.0	287.5	-398.8	751.3	0	0.0%
Calidad_Producto	24.0	227.5	203.5	-281.2	532.8	0	0.0%
Numero_Estrellas	22.8	36.5	13.8	2.1	57.1	3	3.0%

Outliers detectados:

- **Precio (2 outliers):** María (225), Matthew (225) — valores máximos del dataset, pero dentro del rango plausible para productos premium.
- **Servicio_Retorno (13 outliers):** Incluye valores bajos (Xavier=3, Helen=3, Herman=3, Marcel=3, Teresa=3, Sylvester=4, Maksym=4, Anna=4, Stephania=4) y valores altos (Salome=44). Estos representan opiniones extremas sobre el servicio de retorno, que es una variable inherentemente subjetiva.
- **Numero_Estrellas (3 outliers):** Teofan (1), Fedir (2), Iván (2) — clientes muy insatisfechos.

Decisión sobre outliers: No se eliminaron outliers porque:

1. Los valores detectados son **plausibles** dentro el contexto de evaluaciones de productos (no son errores de entrada).
2. El clustering jerárquico con el método de Ward es **robusto** a outliers moderados.
3. Eliminar clientes con opiniones extremas perdería información valiosa sobre segmentos de insatisfacción.

Conclusión de limpieza: El dataset estaba consistente desde el origen. No se requirió imputación, eliminación de duplicados ni tratamiento de outliers.

JUSTIFICACIÓN DE LA ELECCIÓN DE k=5

Aunque el **Silhouette Score** indicó que **k=10** (score = 0.1248) es ligeramente superior a **k=5** (score = 0.1067), se optó por **k=5** como número final de clusters por las siguientes razones:

Interpretabilidad de los Grupos

Aspecto	k=5	k=10
Número de clusters	5 grupos claros	10 grupos fragmentados
Cluster más pequeño	9 clientes (9%)	7 clientes (7%)
Cluster más grande	36 clientes (36%)	15 clientes (15%)
Desv. estándar de tamaños	10.70	2.54
Interpretación de perfiles	Alta: cada cluster tiene un perfil distintivo y accionable	Baja: muchos clusters se vuelven redundantes o difíciles de diferenciar

Con **k=10**, los clusters se vuelven demasiado pequeños (7-15 clientes cada uno), lo que dificulta identificar patrones de comportamiento significativos. Por ejemplo, con k=10:

- **Salomé** queda en un cluster de solo **7 clientes** (con Fabian, Henry, Joachim, Magdalyna, Maya, Myron).
- **Stephania** queda en un cluster de **12 clientes** que incluye a clientes tan dispares como Isidore, Eunice y Louise.

Con **k=5**, los perfiles son mucho más nítidos: Cluster 1 = Premium, Cluster 2 = Equilibrado, Cluster 3 = Gran Formato, Cluster 4 = Valor Educativo, Cluster 5 = Entrega Rápida.

Aplicabilidad Práctica para Recomendaciones

El objetivo del ejercicio es **recomendar productos a clientes basándose en segmentos similares**. Con k=10:

- Los clusters son tan pequeños que las recomendaciones se basarían en muy pocos vecinos, aumentando el riesgo de **sobreajuste** (overfitting).
- Un cluster de 7 clientes no es estadísticamente robusto para generalizar preferencias.

Con k=5:

- Cada cluster tiene entre 9 y 36 clientes, proporcionando una **base suficiente** para identificar patrones reales.
- Las recomendaciones son más **estables** y generalizables.

Principio de Parsimonia (Rasoir d'Ockham)

En clustering, un número menor de grupos suele preferirse cuando la ganancia en Silhouette Score es marginal. La diferencia entre k=5 (0.1067) y k=10 (0.1248) es solo 0.0181, lo cual no justifica duplicar la complejidad del modelo.

Conclusión: Se eligió k=5 porque ofrece el mejor balance entre calidad del agrupamiento, interpretabilidad de los perfiles y aplicabilidad práctica para el sistema de recomendaciones, aunque k=10 tenga un Silhouette Score ligeramente superior.

CARACTERIZACIÓN COMPLETA DE TODOS LOS CLUSTERS

A continuación, se describen los **5 clusters** identificados, incluyendo los clusters 4 y 5 que no habían sido detallados previamente:

CLUSTER 1: Premium Alta Calidad (19 clientes — 19%)

Variable	Promedio	Destacado
Durabilidad	**440.3**	★ Más alto de todos los clusters
Calidad_Producto	**264.5**	★ Más alto de todos los clusters
Numero_Estrellas	**37.1**	Muy alto
Velocidad_Entrega	153.2	Por encima del promedio
Precio	58.5	Moderado-alto
Servicio_Retorno	21.8	Por debajo del promedio

Clientes representativos: Stephania, Judith, Helen, Maura, Mykyta, Markian

Perfil: Clientes exigentes que priorizan la **durabilidad extrema** y la **calidad del producto** por encima de todo. Están dispuestos a pagar precios moderados-altos y valoran la velocidad de entrega. Dan mucha importancia al número de estrellas (satisfacción general), pero no valoran tanto el servicio de retorno. Buscan productos que duren y funcionen impecablemente.

CLUSTER 2: Equilibrado / Económico (36 clientes — 36%)

Variable	Promedio	Destacado
Durabilidad	211.0	Moderado
Imagen_Producto	137.5	Moderado
Precio	**35.7**	★ Más bajo de todos los clusters
Numero_Estrellas	**17.8**	★ Más bajo de todos los clusters
Velocidad_Entrega	72.2	Por debajo del promedio

Clientes representativos: Lydia, Lubomyr, Fialka, Edward, Fedir, Irene

Perfil: El grupo más grande. Clientes que buscan un **balance entre calidad y precio accesible**. No son muy exigentes con la velocidad de entrega ni dan calificaciones extremas. Prefieren productos económicos con durabilidad razonable. Son consumidores pragmáticos que no buscan lo último ni lo más barato, sino una relación calidad-precio sensata.

CLUSTER 3: Gran Formato / Precio Elevado (24 clientes — 24%)

Variable	Promedio	Destacado
Tamano_Paquete	**336.3**	★ Más alto de todos los clusters
Precio	**102.3**	★ Más alto de todos los clusters
Calidad_Producto	**80.9**	★ Más bajo de todos los clusters
Velocidad_Entrega	50.9	Bajo
Valor_Educativo	22.0	Bajo

Clientes representativos: Salome, Magdalyna, Henry, Susanna, Myron, Joachim

Perfil: Clientes que compran **productos de gran tamaño** y están dispuestos a pagar **precios elevados**. Curiosamente, no correlacionan el tamaño con alta calidad (calidad del producto es la más baja de todos los clusters: 80.9). No valoran la velocidad de entrega ni el valor educativo. Parecen comprar artículos voluminosos donde el tamaño físico es más importante que la calidad técnica (ej. muebles, electrodomésticos grandes).

CLUSTER 4: Valor Educativo / Servicio Post-Venta (12 clientes — 12%)

Variable	Promedio	Destacado
Valor_Educativo	**35.0**	★ Más alto de todos los clusters
Servicio_Retorno	**30.8**	★ Más alto de todos los clusters
Numero_Estrellas	**37.9**	★ Más alto de todos los clusters
Durabilidad	257.6	Moderado-alto
Calidad_Producto	**22.8**	★ Más bajo de todos los clusters
Velocidad_Entrega	**29.6**	★ Más bajo de todos los clusters
Imagen_Producto	89.8	Bajo

Clientes representativos: Bernard, Emilia, Philip, Florence, Hilary, Larissa

Perfil: Clientes que priorizan el **aprendizaje** y la **experiencia de uso** sobre la calidad técnica del producto. Valoran extremadamente el servicio de retorno (30.8, el más alto) y dan calificaciones muy altas (37.9 estrellas). Son un nicho pequeño pero fiel. No les importa la velocidad de entrega ni la imagen del producto. Probablemente compran productos didácticos, libros, cursos o herramientas de aprendizaje donde el valor educativo supera a la calidad material.

CLUSTER 5: Entrega Rápida / Baja Durabilidad (9 clientes — 9%)

Variable	Promedio	Destacado
Velocidad_Entrega	**226.1**	★ Más alto de todos los clusters
Tamano_Paquete	182.1	Alto
Numero_Estrellas	37.3	Alto
Durabilidad	**42.7**	★ Más bajo de todos los clusters
Precio	**33.4**	Bajo
Imagen_Producto	80.8	Bajo

Clientes representativos: Xavier, Evdokia, Santiago, Josephine, Lesia, Maksym

Perfil: Clientes **impacientes** que valoran extremadamente la velocidad de entrega (226.1, el más alto de todos). Compran productos de **baja durabilidad** (42.7, el más bajo) a **precios bajos**. Son el grupo más pequeño (9 clientes) y parecen preferir **productos desechables o de consumo rápido**: artículos que necesitan urgentemente, usan por poco tiempo y reemplazan frecuentemente. No les importa la imagen ni la durabilidad, solo que llegue rápido y sea barato.

RESULTADOS POR CLIENTE

1. SALOMÉ → Cluster 3: "Productos de Gran Formato / Precio Elevado"

Table

Vecinos más cercanos	Distancia
Magdalyna	2.77
Henry	2.97
Susanna	3.00
Myron	3.13
Joachim	3.32

Perfil de Salomé: Valora bajo la Velocidad de Entrega (17), Precio (23), Imagen del Producto (41), Valor Educativo (4) y Calidad del Producto (28). Sin embargo, valora alto el Tamaño del Paquete (315) y el Servicio de Retorno (44).

"Recomendaría a Salomé los mismos productos que compró Myron y Joachim" (sus vecinos más cercanos en el cluster). Myron valora significativamente más alto el Tamaño del Paquete (495 vs 315), la Imagen del Producto (225 vs 41), la Calidad del Producto (165 vs 28) y la Durabilidad (355 vs 275). Joachim, por su parte, valora mucho más la Calidad del Producto (195 vs 28), el Tamaño del Paquete (445 vs 315) y el Precio (105 vs 23). Estos clientes pertenecen al mismo segmento de productos de gran formato, pero aprecian más atributos de calidad e imagen que Salomé actualmente no valora.

2. STEPHANIA → Cluster 1: "Productos Premium de Alta Calidad"

Vecinos más cercanos	Distancia
Judith	**1.40**
Helen	**1.91**
Maura	**2.24**
Mykyta	**2.79**
Markian	**3.01**

Perfil de Stephania: Es una cliente exigente que valora muy alto la Durabilidad (465), Imagen del Producto (315), Calidad del Producto (305) y Número de Estrellas (45). Sin embargo, valora extremadamente bajo el Servicio de Retorno (4), mucho menos que sus vecinos de cluster.

"Recomendaría a Stephania los mismos productos que compró Markian y Maura". Aunque Stephania ya valora muy alto los atributos principales de su segmento premium, Markian valora significativamente más alto el Servicio de Retorno (27 vs 4 de Stephania) y Maura valora más la Velocidad de Entrega (265 vs 215). Estos son atributos complementarios dentro del mismo segmento de productos de alta gama que Stephania podría estar descuidando. Judith también es muy cercana (distancia 1.40) y podría servir como referencia adicional.

3. LYDIA → Cluster 2: "Productos Equilibrados / Económicos"

Vecinos más cercanos	Distancia
Lubomyr	1.51
Fialka	1.68
Edward	1.92
Fedir	1.98
Irene	2.01

Perfil de Lydia: Valora muy alto la Durabilidad (435) y la Calidad del Producto (185), pero valora bajo la Velocidad de Entrega (19), el Precio (4), el Valor Educativo (16) y el Tamaño del Paquete (28).

"Recomendaría a Lydia los mismos productos que compró Edward y Lubomyr". Edward valora mucho más alto la Imagen del Producto (295 vs 145 de Lydia) y la Velocidad de Entrega (135 vs 19). Lubomyr también valora más alto la Imagen del Producto (245 vs 145). Ambos son vecinos cercanos dentro del mismo cluster de productos equilibrados, pero aprecian más la presentación visual y la rapidez de entrega, aspectos que Lydia subvalora a pesar de estar en el mismo segmento de preferencias.

PERFILES DE LOS 5 CLUSTERS IDENTIFICADOS

Cluster	Nombre	Características Principales	Tamaño
1	Premium Alta Calidad	Alta durabilidad (440), calidad (264), estrellas (37)	19
2	Equilibrado/Económico	Precio bajo (36), durabilidad media (211), estrellas bajo (18)	36
3	Gran Formato/Precio Elevado	Tamaño paquete muy alto (336), precio alto (102), calidad baja (81)	24
4	Valor Educativo/Retorno	Valor educativo alto (35), servicio retorno alto (31), calidad muy baja (23)	12
5	Entrega Rápida/Baja Durabilidad	Velocidad entrega muy alta (226), durabilidad muy baja (43)	9

RESUMEN DE RECOMENDACIONES FINALES

SALOMÉ (Cluster 3 - Gran Formato/Precio Elevado)

→ Recomendar los mismos productos que: Myron y Joachim

→ Razón: Valoran más alto Calidad, Imagen, Durabilidad y Tamaño Paquete

STEPHANIA (Cluster 1 - Premium Alta Calidad)

→ Recomendar los mismos productos que: Markian y Maura

→ Razón: Valoran más alto Servicio Retorno y Velocidad Entrega

LYDIA (Cluster 2 - Equilibrado/Económico)

→ Recomendar los mismos productos que: Edward y Lubomyr

→ Razón: Valoran más alto Imagen Producto y Velocidad Entrega

Conclusión

El clustering jerárquico permitió segmentar a los 100 clientes de Amazon en **5 grupos homogéneos** con perfiles de preferencias claramente diferenciados. Para las tres clientes consultadas:

Cliente	Cluster	Recomendación Principal	Atributos a Explorar
Salomé	3	Myron y Joachim	Calidad, Imagen, Durabilidad
Stephania	1	Markian y Maura	Servicio Retorno, Velocidad Entrega
Lydia	2	Edward y Lubomyr	Imagen Producto, Velocidad Entrega

Esta estrategia de recomendación basada en **vecinos más cercanos dentro del mismo cluster** maximiza la probabilidad de que los productos sugeridos sean relevantes, ya que provienen de clientes con perfiles de preferencias estadísticamente similares.