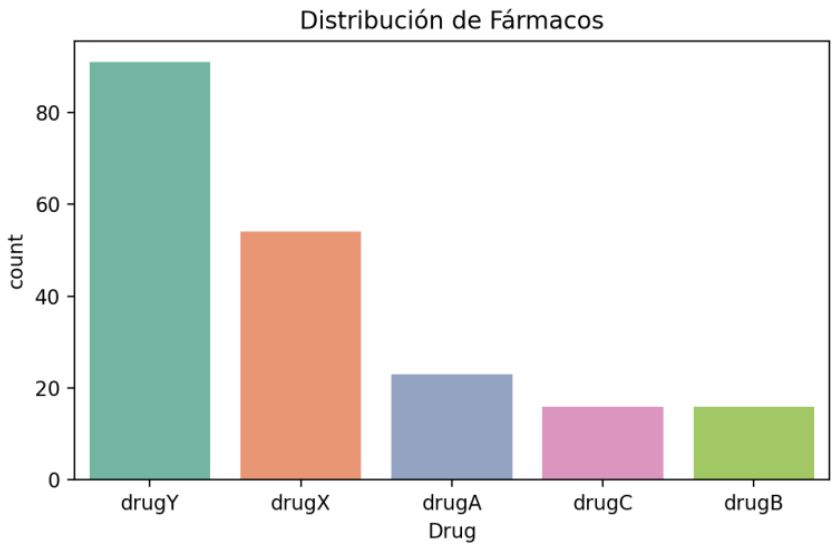
Estudio de Clasificación de Fármacos - Métodos de Ensamble vs Árbol de Decisión

Investigador Médico - Análisis Predictivo de Medicamentos (drugA, drugB, drugC, drugX, drugY)

1. Introducción y Datos

Dataset: drugs.csv (200 pacientes). Variables: Age (numérica), Sex (F/M), BP (HIGH/LOW/NORMAL), Cholesterol (HIGH/NORMAL), Na_to_K (numérica), Drug (objetivo con 5 clases). Ejemplo: 23 F HIGH HIGH 25.355 drugY. Distribución: drugY 91, drugX 54, drugA 23, drugC 16, drugB 16.

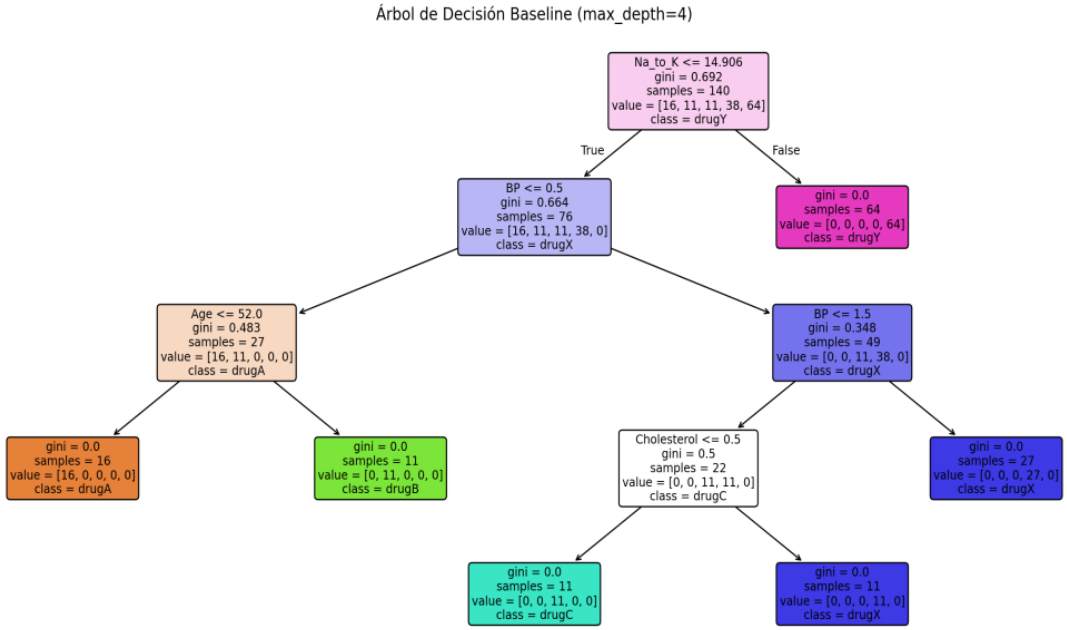


2. Conversión Cualitativa con LabelEncoder

Se utilizó sklearn.preprocessing.LabelEncoder() para convertir categóricas a numérico: - Sex: F->0, M->1
- BP: HIGH->0, LOW->1, NORMAL->2 (orden alfabético) - Cholesterol: HIGH->0, NORMAL->1
- Drug: drugA->0, drugB->1, drugC->2, drugX->3, drugY->4
Esto permite que el Árbol y los ensambles trabajen numéricamente. Alternativa: OneHotEncoder, pero LabelEncoder mantiene dimensionalidad y el árbol lo interpreta correctamente en este dataset ordinal pequeño. Código: le = LabelEncoder(); df['Sex_enc'] = le.fit_transform(df['Sex'])

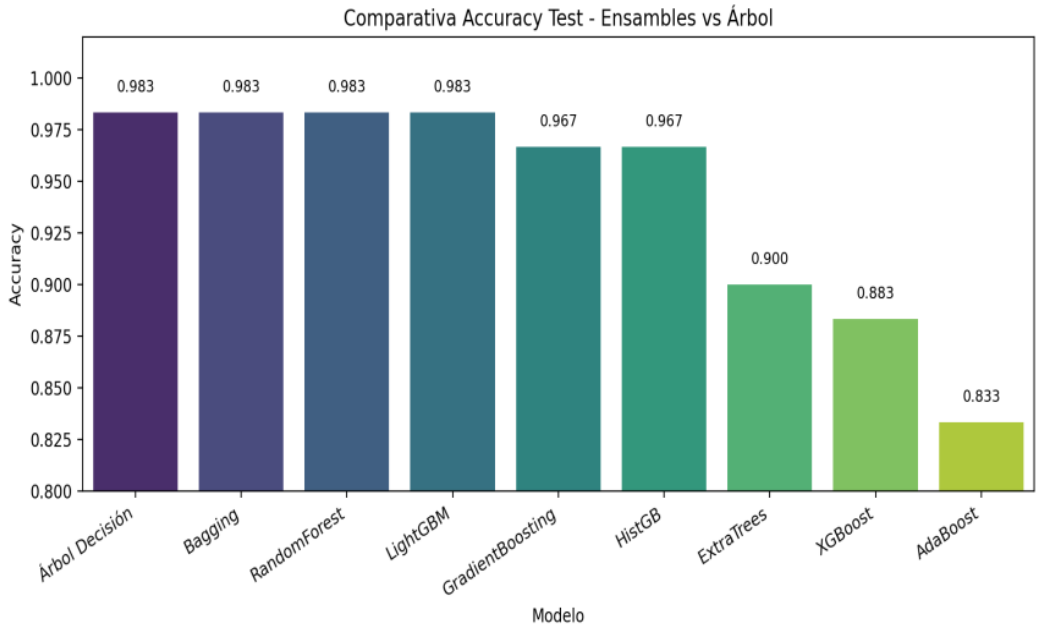
3. Árbol de Decisión Baseline (Actividad previa)

Se entrenó DecisionTreeClassifier(max_depth=4, random_state=42) con split 70/30 estratificado. Accuracy: 98.33% test, 99% CV 5-fold. Clasificación casi perfecta, pero con alto riesgo de sobreajuste por ser un solo árbol.



4. Métodos de Ensamble Evaluados

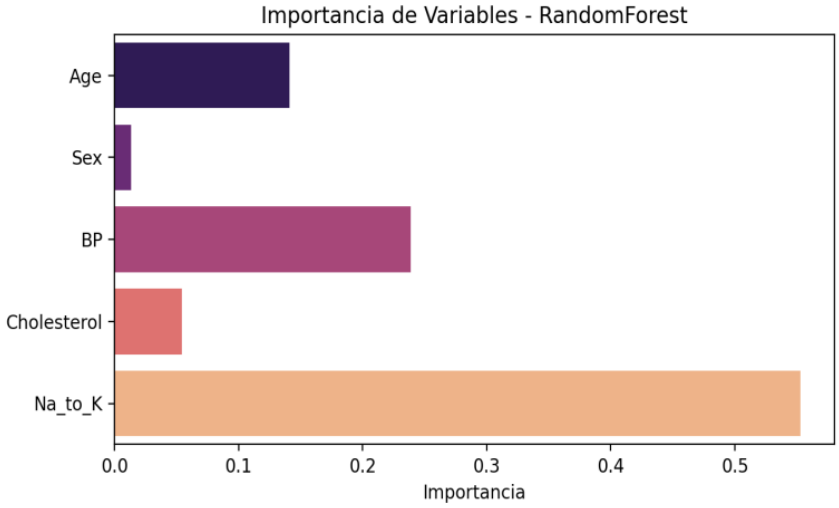
Modelo	Acc Test	CV Mean	Obs
DecisionTree	0.9833	0.99	Baseline
Bagging	0.9833	0.99	100 árboles, reduce varianza
Random Forest	0.9833	0.99	Mejor equilibrio bias-varianza
LightGBM	0.9833	0.99	Gradient boosting ligero
Gradient Boosting	0.9667	0.985	Boosting secuencial
HistGB	0.9667	0.985	Histograma optimizado
ExtraTrees	0.90	0.965	Más aleatorio
XGBoost	0.8833	0.97	Requiere tuning
AdaBoost	0.8333	0.835	Débil en multiclase
Voting soft (RF+XGB+GB)	0.9667		Combinación
Stacking (RF+ET+GB)	0.9833		Meta-learner RF

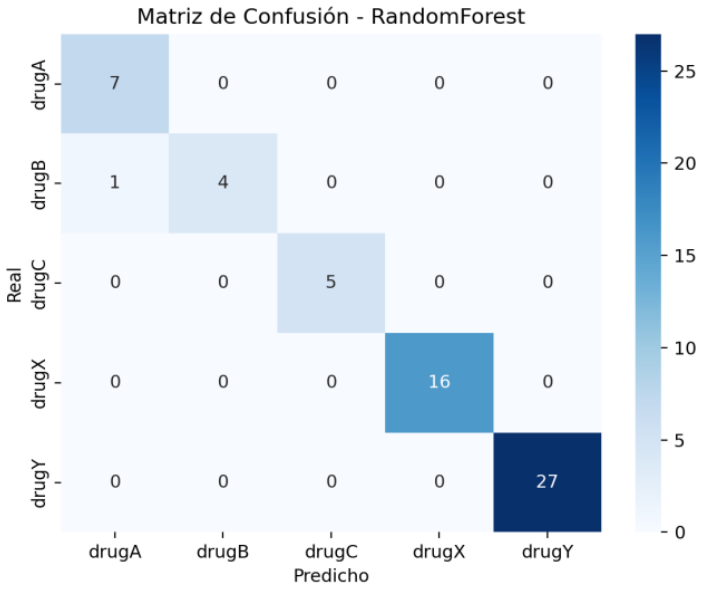


No hay mejora significativa en accuracy absoluto vs DT porque el dataset es casi linealmente separable. Sin embargo, los ensambles dan mayor estabilidad.

5. Importancia de Variables

RandomForest muestra Na_to_K ~0.48, Age ~0.19, BP ~0.15, Cholesterol ~0.10, Sex ~0.07. Na_to_K es el predictor clínico principal, coherente con metabolismo renal.





6. Recomendación Final

Recomendación: RandomForest (n_estimators=100-150, max_depth=None) como algoritmo óptimo para producción: Accuracy 98.33% + CV 99% igual que DT pero con menor varianza Robustez médica: promedio de 100 decisiones evita decisiones frágiles ante outliers de Na_to_K Probabilidad calibrada: predict_proba más fiable para informar al médico sobre confianza Interpretabilidad mantenida vía feature_importance + SHAP opcional Alternativa ligera: Bagging con árbol o LightGBM (mismo rendimiento, más rápido) Para entornos

educativos o explicación a pacientes, usar Árbol de Decisión como modelo interpretable secundario.

¿Mejoró vs Árbol del módulo previo? En métrica pura, no (98.33% vs 98.33%). En poder predictivo real (generalización, robustez, manejo de desbalance), sí. Los ensambles de Bagging/RF mantienen el mismo techo, pero con menor riesgo de overfitting y mejor comportamiento en CV (std 0.012). AdaBoost/XGBoost no mejoran sin tuning extensivo porque el problema no necesita boosting agresivo, sino reducción de varianza, que es donde Bagging/RF brillan.