Análisis de Rotación de Empleados con SVM

Objetivo: Predecir la variable left (abandono) usando SVM con kernel linear, rbf, poly y sigmoid.
Pasos: Carga csv, recodificación con pd.get_dummies (sales, salary), split 70/30 estratificado, StandardScaler, entrenamiento SVM.

Resumen comparativo de métricas

Kernel	Accuracy	Precision clase 1	Recall clase 1	F1 clase 1
Linear	0.7742	0.55	0.26	0.36
rbf	0.9487	0.89	0.89	0.89
poly	0.9340	0.90	0.81	0.85
sigmoid	0.6447	0.23	0.22	0.22

Interpretación de indicadores por kernel

1. Kernel LINEAL (Accuracy 0.7742)

Matriz: Muchos falsos negativos (empleados que se van, pero predice que se quedan).
Reporte: Para clase 1 (Se va): Precision 0.55, Recall 0.26, F1 0.36 -> El modelo es muy malo detectando a quienes abandonan. Solo detecta 26% de los que realmente se van.
Interpretación: Datos no son linealmente separables. El problema HR es altamente no lineal (interacción satisfacción-horas-evaluación).

2. Kernel RBF (Radial Basis Function) (Accuracy 0.9487) -> MEJOR MODELO

Matriz: [3325 TP clase 0, 954 TP clase 1] aprox. Muy equilibrado.
Reporte: Clase 0: Prec 0.97, Rec 0.97, F1 0.97 | Clase 1: Prec 0.89, Rec 0.89, F1 0.89
Interpretación: Excelente generalización. RBF puede modelar fronteras no lineales complejas propias de RRHH (ej.: empleados con baja satisfacción + horas extremas, o alta evaluación, pero baja satisfacción). Alta capacidad para capturar clusters.

3. Kernel POLY (Polinomial) (Accuracy 0.9340)

Matriz: Similar a RBF, pero con un poco más de falsos negativos en clase 1.

Reporte: Clase 1: Prec 0.90, Rec 0.81, F1 0.85 -> Buena precision (cuando dice que se va, 90% acierta) pero recall menor que RBF (pierde 19% de los que se van).
Interpretación: También capta no linealidad, pero polinomio de grado 3 por defecto puede sobre ajustar o ser menos flexible que RBF.

4. Kernel SIGMOID (Accuracy 0.6447) -> PEOR MODELO
Reporte: Clase 1: Prec 0.23, Rec 0.22, F1 0.22 -> Prácticamente no sirve.
Interpretación: Sigmoid se comporta como red neuronal de una capa; sin tuning de coef0 y gamma, no separa bien. No apropiado para este dataset sin hiperparámetros.

Conclusión sobre métricas importantes: En RRHH, **Recall de clase 1 es crítico** (queremos detectar a quién se va a ir para retenerlo). Un falso negativo cuesta más que un falso positivo. Por eso RBF gana: recall 0.89 vs 0.81 poly vs 0.26 linear.

¿Cuál resultó ser el modelo predictivo más adecuado?

Respuesta: SVM con kernel RBF.

Razonamiento:

1. **Mayor Accuracy (94.87%)** y mejor F1 macro (0.93)
2. **Mejor equilibrio Precision-Recall** para la clase minoritaria (left=1). En retención, queremos minimizar tanto falsos positivos (gastar recursos en quien no se iba) como falsos negativos (perder talento sin advertencia). RBF logra ~0.89 en ambas.
3. **Capacidad no lineal:** Los análisis exploratorios muestran que las razones de abandono no son lineales: hay 3 grupos que se van - (a) baja satisfacción (<0.2), (b) sobre-trabajados (>250h) con satisfacción media-alta, pero evaluación alta, (c) con 4-5 años en empresa sin promoción. RBF con su función gaussiana crea fronteras locales capaces de capturar esos 3 clusters.
4. Poly es segundo mejor, pero pierde recall; lineal y sigmoid infra-ajustan.

Recomendación para producción: Usar RBF con tuning de C y gamma vía GridSearchCV, y posiblemente balanceo de clases (class_weight='balanced').

Conclusión.

- Se cumplieron: recodificación con get_dummies, escalado StandardScaler, prueba 4 kernels, heatmaps, reportes.

- Modelo elegido: RBF.
- Predicción: El caso clásico de alto riesgo (0.11 satisfacción, 272h, 7 proyectos) -> **todos los kernels RBF y POLY predicen SE VA (1)**. Linear a veces falla. Sigmoid inestable.
- Para empresa: intervenir en empleados con satisfacción <0.3, horas >240, tiempo 3-5 años sin promoción.