Importación de librerías y carga del archivo csv.

1. Objetivos, fuente y metodología

Se utilizan los 21,613 registros del archivo proporcionado. Se descartan `id`, `date` y `zipcode` por su interpretación como identificadores/ubicación categórica; `sqft_above` y `sqft_basement` se excluyen por la identidad `sqft_living = sqft_above + sqft_basement`, que introduce dependencia lineal exacta si se incluyen simultáneamente. `lat` y `long` representan ubicación como coordenadas numéricas. Se emplea separación 80/20 con semilla 42 para evaluar generalización. La selección de variables se realiza **solo sobre entrenamiento**.

[1]:
```
import numpy as np
import pandas as pd
import matplotlib.pyplot as plt
from scipy.stats import t as tdist
from sklearn.model_selection import train_test_split
from sklearn.metrics import r2_score, mean_absolute_error, mean_squared_error
import warnings
warnings.filterwarnings("ignore")
import os
os.chdir("/Users/zrgv/OneDrive/Documentos/Cientifico de datos ebac/Modulo 53")

df = pd.read_csv("kc_house_data.csv")


print("Dimensiones:", df.shape); display(df.head()); print(df.isna().sum())
```

```
Dimensiones: (21613, 21)
```

	id	date	price	bedrooms	bathrooms	sqft_living	sqft_lot	floors	waterfront	view	...	grade	sqft_above	sqft_basement	yr_built	yr_re
0	7129300520	20141013T000000	221900.0	3	1.00	1180	5650	1.0	0	0	...	7	1180	0	1955	
1	6414100192	20141209T000000	538000.0	3	2.25	2570	7242	2.0	0	0	...	7	2170	400	1951	
2	5631500400	20150225T000000	180000.0	2	1.00	770	10000	1.0	0	0	...	6	770	0	1933	
3	2487200875	20141209T000000	604000.0	4	3.00	1960	5000	1.0	0	0	...	7	1050	910	1965	

0	7129300520	20141013T000000	221900.0	3	1.00	1180	5650	1.0	0	0	...	7	1180	0	1955	
1	6414100192	20141209T000000	538000.0	3	2.25	2570	7242	2.0	0	0	...	7	2170	400	1951	
2	5631500400	20150225T000000	180000.0	2	1.00	770	10000	1.0	0	0	...	6	770	0	1933	
3	2487200875	20141209T000000	604000.0	4	3.00	1960	5000	1.0	0	0	...	7	1050	910	1965	
4	1954400510	20150218T000000	510000.0	3	2.00	1680	8080	1.0	0	0	...	8	1680	0	1987	

5 rows × 21 columns

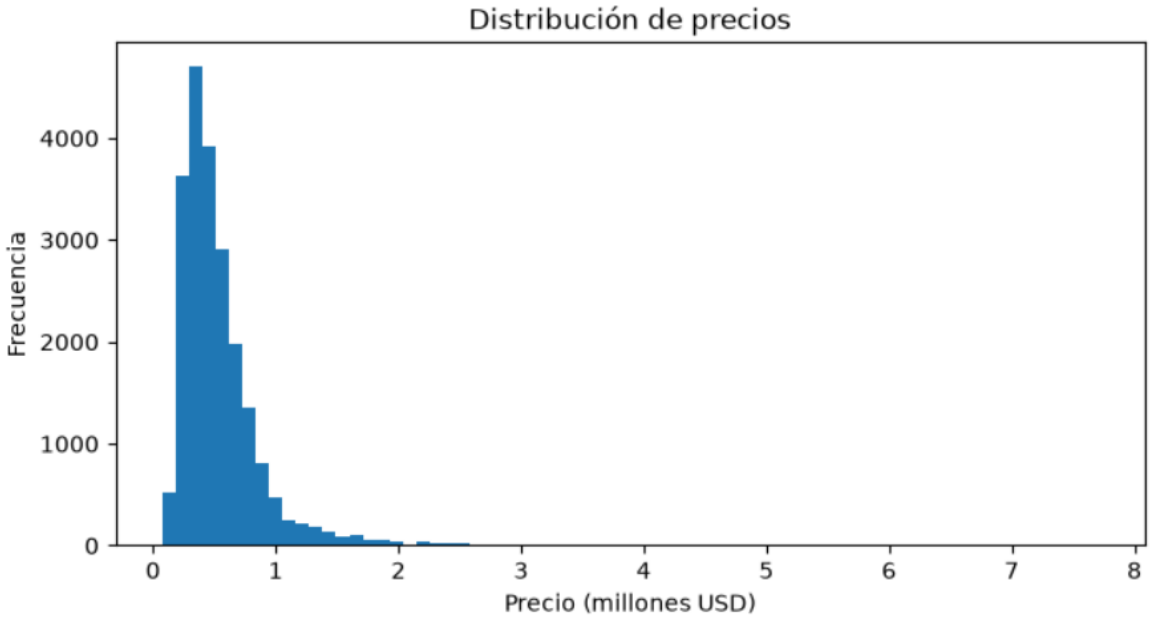
```
id               0
date             0
price            0
bedrooms         0
bathrooms        0
sqft_living      0
sqft_lot         0
floors           0
waterfront       0
view             0
condition        0
grade            0
sqft_above       0
sqft_basement    0
yr_built         0
yr_renovated     0
zipcode          0
lat              0
long             0
sqft_living15    0
sqft_lot15       0
dtype: int64
```

Análisis exploratorio y distribución de precios.

2. Análisis exploratorio ¶

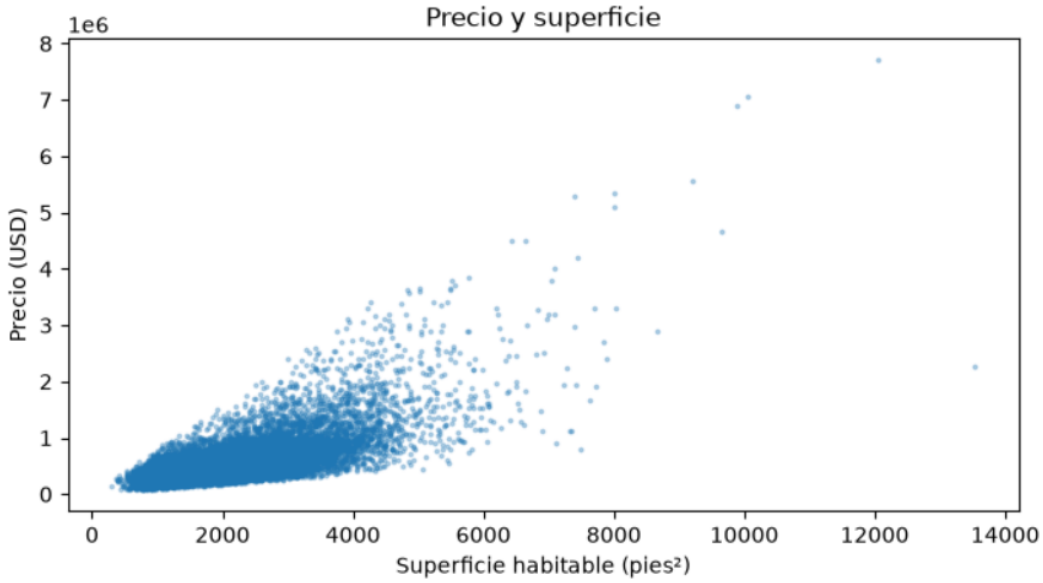
[2]:
```
display(df.describe().T.round(2))
fig,ax=plt.subplots(figsize=(8,4));
ax.hist(df.price/1e6,bins=70);
ax.set(xlabel="Precio (millones USD)",ylabel="Frecuencia",title="Distribución de precios");
plt.show()
```

	count	mean	std	min	25%	50%	75%	max
id	21613.0	4.580302e+09	2.876566e+09	1000102.00	2.123049e+09	3.904930e+09	7.308900e+09	9.900000e+09
price	21613.0	5.400881e+05	3.671272e+05	75000.00	3.219500e+05	4.500000e+05	6.450000e+05	7.700000e+06
bedrooms	21613.0	3.370000e+00	9.300000e-01	0.00	3.000000e+00	3.000000e+00	4.000000e+00	3.300000e+01
bathrooms	21613.0	2.110000e+00	7.700000e-01	0.00	1.750000e+00	2.250000e+00	2.500000e+00	8.000000e+00
sqft_living	21613.0	2.079900e+03	9.184400e+02	290.00	1.427000e+03	1.910000e+03	2.550000e+03	1.354000e+04
sqft_lot	21613.0	1.510697e+04	4.142051e+04	520.00	5.040000e+03	7.618000e+03	1.068800e+04	1.651359e+06
floors	21613.0	1.490000e+00	5.400000e-01	1.00	1.000000e+00	1.500000e+00	2.000000e+00	3.500000e+00
waterfront	21613.0	1.000000e-02	9.000000e-02	0.00	0.000000e+00	0.000000e+00	0.000000e+00	1.000000e+00
view	21613.0	2.300000e-01	7.700000e-01	0.00	0.000000e+00	0.000000e+00	0.000000e+00	4.000000e+00
condition	21613.0	3.410000e+00	6.500000e-01	1.00	3.000000e+00	3.000000e+00	4.000000e+00	5.000000e+00
grade	21613.0	7.660000e+00	1.180000e+00	1.00	7.000000e+00	7.000000e+00	8.000000e+00	1.300000e+01
sqft_above	21613.0	1.788390e+03	8.280900e+02	290.00	1.190000e+03	1.560000e+03	2.210000e+03	9.410000e+03
sqft_basement	21613.0	2.915100e+02	4.425800e+02	0.00	0.000000e+00	0.000000e+00	5.600000e+02	4.820000e+03



Precio y superficie.

[3]:
```
fig,ax=plt.subplots(figsize=(8,4));
ax.scatter(df.sqft_living,df.price,s=3,alpha=.3);
ax.set(xlabel="Superficie habitable (pies²)",ylabel="Precio (USD)",title="Precio y superficie");
plt.show()
```



Modelo matricial e inferencia

3. Modelo matricial e inferencia

Sea X la matriz de diseño con intercepto y y el vector de precios. Estimamos $\hat{\beta} = (X^T X)^{-1} X^T y$, implementado mediante `np.linalg.lstsq` para mayor estabilidad numérica. La matriz de covarianza estimada es $\hat{\sigma}^2 (X^T X)^{-1}$, con $\hat{\sigma}^2 = RSS/(n-p)$. Cada prueba contrasta $H_0 : \beta_j = 0$ frente a $H_1 : \beta_j \neq 0$. Se estandarizan predictores con parámetros calculados **solo en entrenamiento** para mejorar el condicionamiento; los contrastes t de pendientes no cambian por ese reescalamiento.

[4]:
```
features = ['bedrooms', 'bathrooms', 'sqft_living', 'sqft_lot', 'floors', 'waterfront', 'view', 'condition', 'grade', 'yr_built', 'yr_renovated',
            'lat', 'long', 'sqft_living15', 'sqft_lot15']
train,test=train_test_split(df,test_size=.2,random_state=42)
mu=train[features].mean();sd=train[features].std().replace(0,1)
def fit_matrix(cols):
    X=np.column_stack([np.ones(len(train)),((train[cols]-mu[cols])/sd[cols]).to_numpy()]);y=train.price.to_numpy()
    beta=np.linalg.lstsq(X,y,rcond=None)[0]
    residual=y-X@beta;n,p=X.shape;dof=n-p
    s2=(residual@residual)/dof
    cov=s2*np.linalg.inv(X.T@X)
    se=np.sqrt(np.diag(cov)); t_stat=beta/se
    p_values=2*tdist.sf(np.abs(t_stat),dof)
    critical=tdist.ppf(.975,dof)
    ci=np.column_stack([beta-critical*se,beta+critical*se])
    return beta,se,t_stat,p_values,ci,dof
print("Variables iniciales:",features)
```

```
Variables iniciales: ['bedrooms', 'bathrooms', 'sqft_living', 'sqft_lot', 'floors', 'waterfront', 'view', 'condition', 'grade', 'yr_built', 'yr_renovat
ed', 'lat', 'long', 'sqft_living15', 'sqft_lot15']
```

StepWise.

4. StepWise: eliminación hacia atrás

Se retira iterativamente el predictor con el mayor valor p si supera $\alpha = 0.05$. El intercepto permanece. Este procedimiento es una modalidad **backward** de selección StepWise, no una búsqueda exhaustiva ni una selección bidireccional. Sus valores p posteriores a la selección deben interpretarse como exploratorios, pues no ajustan por selección múltiple.

```
selected=features.copy();history=[]
while True:
    beta,se,t_stat,p_values,ci,dof=fit_matrix(selected)
    i=int(np.argmax(p_values[1:]));worst=float(p_values[i+1])
    if worst<=0.05:break
    history.append((selected.pop(i),worst))
print("Eliminadas (variable, p al eliminar):",history)
print("Seleccionadas:",selected)
```

```
Eliminadas (variable, p al eliminar): [('sqft_lot', 0.10704142594353848)]
Seleccionadas: ['bedrooms', 'bathrooms', 'sqft_living', 'floors', 'waterfront', 'view', 'condition', 'grade', 'yr_built', 'yr_renovated', 'lat', 'lon
g', 'sqft_living15', 'sqft_lot15']
```

Tres enfoques de pruebas de hipótesis

5. Tres enfoques de pruebas de hipótesis

Enfoque 1 (t crítico): rechazar H_0 si $|t_j| > t_{0.975,n-p}$. **Enfoque 2 (p):** rechazar si $p_j < 0.05$. **Enfoque 3 (IC95):** rechazar si el intervalo no contiene cero. Para una prueba bilateral al 5 %, los tres criterios son matemáticamente equivalentes para el mismo ajuste.

[6]:
```
beta,se,t_stat,p_values,ci,dof=fit_matrix(selected)
critical=tdist.ppf(.975,dof)
result=pd.DataFrame({"variable":["Intercepto"]+selected,"beta":beta,"SE":se,"t":t_stat,"p":p_values,"IC95_inf":ci[:,0],"IC95_sup":ci[:,1]})
result["t_critico"]=critical
result["significativo_t"]=np.abs(result.t)>critical
result["significativo_p"]=result.p<.05
result["significativo_IC"]=~((result.IC95_inf<=0)&(result.IC95_sup>=0))
display(result.round(5));print("t crítico bilateral:",critical,"grados de libertad:",dof)
assert (result.significativo_t==result.significativo_p).all() and (result.significativo_p==result.significativo_IC).all()
```

	variable	beta	SE	t	p	IC95_inf	IC95_sup	t_critico	significativo_t	significativo_p	significativo_IC
0	Intercepto	537768.04795	1520.61315	353.65211	0.00000	534787.49210	540748.60380	1.9601	True	True	True
1	bedrooms	-30808.41331	1952.61532	-15.77802	0.00000	-34635.73717	-26981.08945	1.9601	True	True	True
2	bathrooms	31998.14601	2753.95598	11.61898	0.00000	26600.11327	37396.17874	1.9601	True	True	True
3	sqft_living	151311.10308	3392.19870	44.60561	0.00000	144662.04993	157960.15622	1.9601	True	True	True
4	floors	7144.16283	1937.45104	3.68740	0.00023	3346.56249	10941.76317	1.9601	True	True	True
5	waterfront	48316.13239	1658.33402	29.13534	0.00000	45065.62970	51566.63509	1.9601	True	True	True
6	view	36507.46744	1779.69991	20.51327	0.00000	33019.07529	39995.85958	1.9601	True	True	True
7	condition	17787.01838	1685.29374	10.55425	0.00000	14483.67190	21090.36486	1.9601	True	True	True
8	grade	114814.37693	2767.86314	41.48123	0.00000	109389.08475	120239.66911	1.9601	True	True	True

	variable	beta	SE	t	p	IC95_inf	IC95_sup	t_critico	significativo_t	significativo_p	significativo_IC
0	Intercepto	537768.04795	1520.61315	353.65211	0.00000	534787.49210	540748.60380	1.9601	True	True	True
1	bedrooms	-30808.41331	1952.61532	-15.77802	0.00000	-34635.73717	-26981.08945	1.9601	True	True	True
2	bathrooms	31998.14601	2753.95598	11.61898	0.00000	26600.11327	37396.17874	1.9601	True	True	True
3	sqft_living	151311.10308	3392.19870	44.60561	0.00000	144662.04993	157960.15622	1.9601	True	True	True
4	floors	7144.16283	1937.45104	3.68740	0.00023	3346.56249	10941.76317	1.9601	True	True	True
5	waterfront	48316.13239	1658.33402	29.13534	0.00000	45065.62970	51566.63509	1.9601	True	True	True
6	view	36507.46744	1779.69991	20.51327	0.00000	33019.07529	39995.85958	1.9601	True	True	True
7	condition	17787.01838	1685.29374	10.55425	0.00000	14483.67190	21090.36486	1.9601	True	True	True
8	grade	114814.37693	2767.86314	41.48123	0.00000	109389.08475	120239.66911	1.9601	True	True	True
9	yr_built	-74966.84892	2360.22281	-31.76262	0.00000	-79593.12476	-70340.57307	1.9601	True	True	True
10	yr_renovated	8628.83782	1630.73578	5.29138	0.00000	5432.43047	11825.24516	1.9601	True	True	True
11	lat	75566.63900	1601.06846	47.19763	0.00000	72428.38260	78704.89540	1.9601	True	True	True
12	long	-11418.96991	1828.88922	-6.24366	0.00000	-15003.77808	-7834.16175	1.9601	True	True	True
13	sqft_living15	20462.31725	2574.43779	7.94827	0.00000	15416.15835	25508.47615	1.9601	True	True	True
14	sqft_lot15	-6237.88698	1604.60084	-3.88750	0.00010	-9383.06720	-3092.70676	1.9601	True	True	True

```
t crítico bilateral: 1.9601013179481683 grados de libertad: 17275
```

Pronóstico y métricas en datos no utilizados para ajustar ni seleccionar

6. Pronóstico y métricas en datos no utilizados para ajustar ni seleccionar ¶

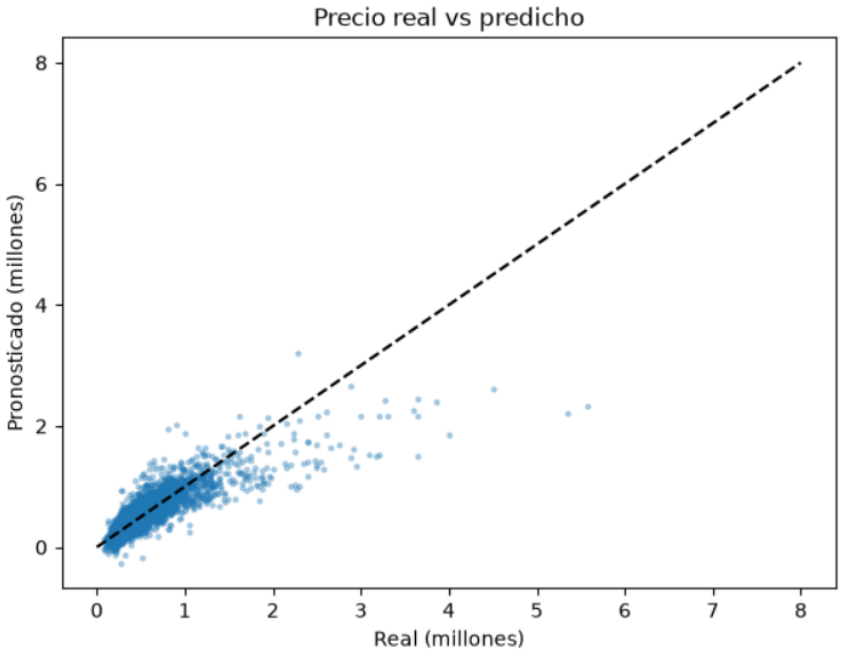
Las métricas R^2, MAE y RMSE se calculan sobre el conjunto de prueba. El desempeño no prueba causalidad ni garantiza validez de los supuestos de errores independientes, homocedásticos y normales.

[7]:
```
def predict(frame,cols,beta):
    X=np.column_stack([np.ones(len(frame)),((frame[cols]-mu[cols])/sd[cols]).to_numpy()]);return X@beta
y_test=test.price.to_numpy();pred=predict(test,selected,beta)
full_beta=fit_matrix(features)[0];pred_full=predict(test,features,full_beta)
summary=pd.DataFrame({"Modelo":["Completo","StepWise"],"R2":[r2_score(y_test,pred_full),r2_score(y_test,pred)],"MAE_USD":[mean_absolute_error(y_test,pre
display(summary.round(3))
```

	Modelo	R2	MAE_USD	RMSE_USD
0	Completo	0.695	128062.817	214744.877
1	StepWise	0.695	128195.576	214850.210

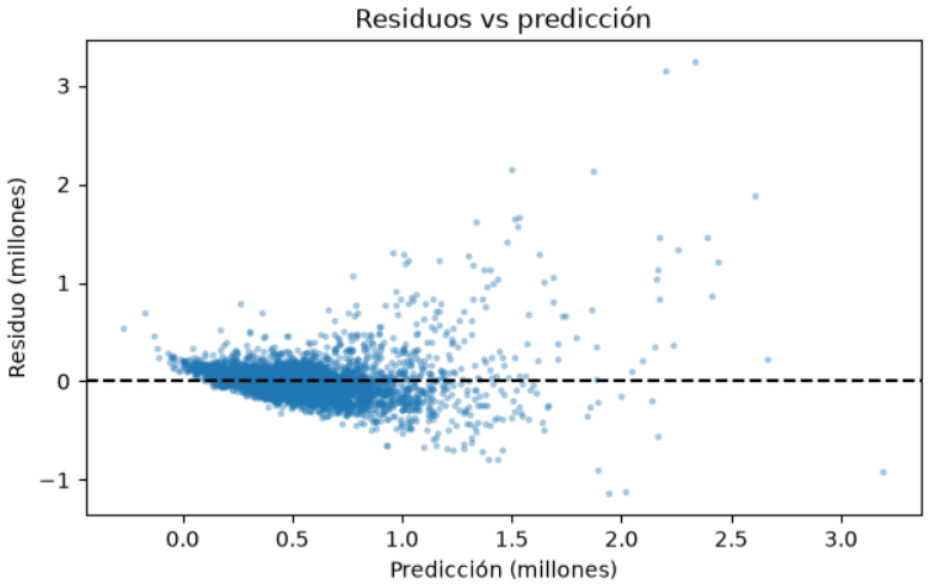
Precio real vs predicho

[8]:
```
fig,ax=plt.subplots(figsize=(7,5));ax.scatter(y_test/1e6,pred/1e6,s=5,alpha=.3);ax.plot([0,8],[0,8],"k--");
ax.set(xlabel="Real (millones)",ylabel="Pronosticado (millones)",title="Precio real vs predicho");
plt.show()
```



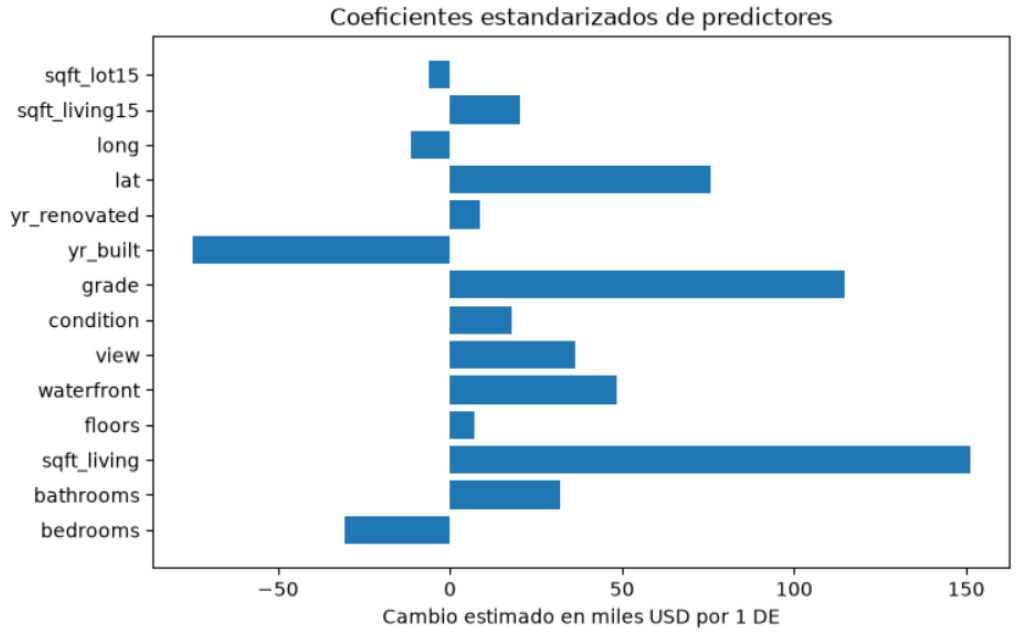
Residuos vs predicción

[9]:
```
fig,ax=plt.subplots(figsize=(7,4));
ax.scatter(pred/1e6,(y_test-pred)/1e6,s=5,alpha=.3);
ax.axhline(0,color="black",ls="--");
ax.set(xlabel="Predicción (millones)",ylabel="Residuo (millones)",title="Residuos vs predicción");
plt.show()
```



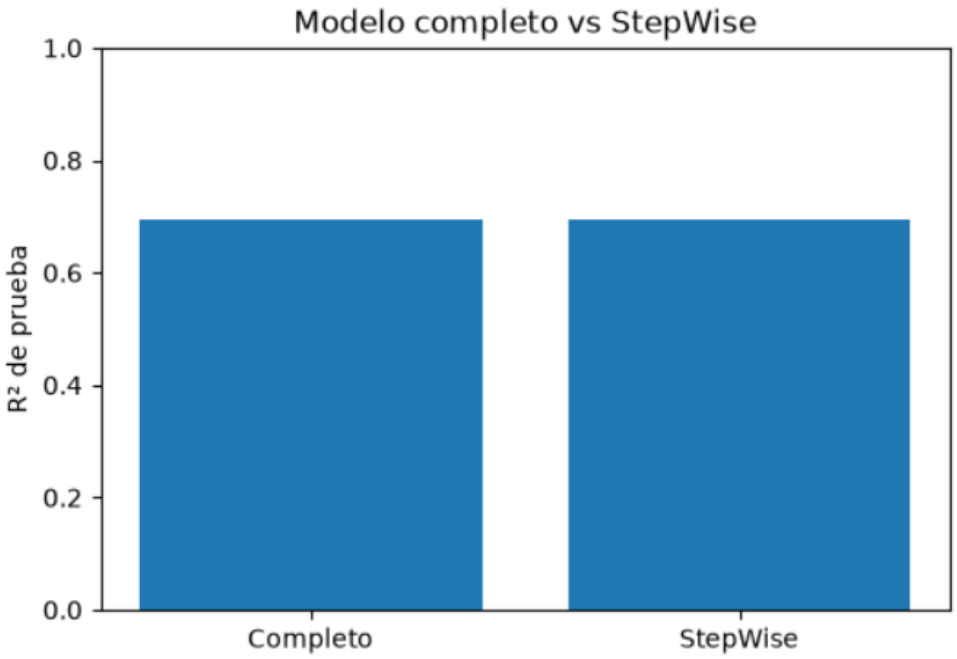
Coeficientes estandarizados de predictores.

[10]:
```
fig,ax=plt.subplots(figsize=(8,5));
ax.barh(selected,beta[1:]/1000);
ax.set(xlabel="Cambio estimado en miles USD por 1 DE",title="Coeficientes estandarizados de predictores");
plt.show()
```



Modelo completo vs StepWise

[11]:
```
fig,ax=plt.subplots(figsize=(6,4));
ax.bar(summary["Modelo"],summary["R2"]);
ax.set(ylim=(0,1),ylabel="R² de prueba",title="Modelo completo vs StepWise");
plt.show()
```



Interpretación y Limitaciones

7. Interpretación y limitaciones

La significancia estadística significa evidencia de asociación parcial distinta de cero bajo los supuestos del modelo; no implica causalidad ni importancia económica. Los coeficientes se interpretan como cambio en USD ante una desviación estándar del predictor, manteniendo constantes los demás. El intercepto representa el precio estimado cuando los predictores toman sus medias de entrenamiento.

Limitaciones: selección automática puede sesgar inferencias; las observaciones de viviendas pueden presentar heterocedasticidad, valores extremos, no linealidad y dependencia espacial. Un siguiente paso sería verificar VIF, usar errores estándar robustos, comparar validación cruzada y considerar transformaciones de precio y modelos no lineales.

```
print("CONCLUSIONES AUTOMÁTICAS")
print("Variables eliminadas:",history if history else "Ninguna")
print("Variables finales:",selected)
print(f"R² prueba={r2_score(y_test,pred):.4f}; MAE=${mean_absolute_error(y_test,pred):,.2f}; RMSE=${np.sqrt(mean_squared_error(y_test,pred)):,.2f}")
print("Los tres enfoques coinciden:",bool((result.significativo_t==result.significativo_p).all() and (result.significativo_p==result.significativo_IC).a
result.to_csv("resultados_coeficientes.csv",index=False)
```

```
CONCLUSIONES AUTOMÁTICAS
Variables eliminadas: [('sqft_lot', 0.10704142594353848)]
Variables finales: ['bedrooms', 'bathrooms', 'sqft_living', 'floors', 'waterfront', 'view', 'condition', 'grade', 'yr_built', 'yr_renovated', 'lat', 'l
ong', 'sqft_living15', 'sqft_lot15']
R² prueba=0.6947; MAE=$128,195.58; RMSE=$214,850.21
Los tres enfoques coinciden: True
```