CARGA Y EXPLORACIÓN DE DATOS.

Dimensiones: 150 filas × 5 columnas

Variables numéricas: sepal.length, sepal.width, petal.length, petal.width

Variable categórica: variety (Setosa, Versicolor, Virginica)

Primeras 10 filas:

Índice	sepal.length	sepal.width	petal.length	petal.width	Variety
0	5.1	3.5	1.4	0.2	Setosa
1	4.9	3.0	1.4	0.2	Setosa
2	4.7	3.2	1.3	0.2	Setosa
3	4.6	3.1	1.5	0.2	Setosa
4	5.0	3.6	1.4	0.2	Setosa
5	5.4	3.9	1.7	0.4	Setosa
6	4.6	3.4	1.4	0.3	Setosa
7	5.0	3.4	1.5	0.2	Setosa
8	4.4	2.9	1.4	0.2	Setosa
9	4.9	3.1	1.5	0.1	Setosa

Resumen estadístico:

Variable	Media	Std	Min	Max
sepal.length	5.843	0.828	4.3	79
sepal.width	3.057	0.436	2.0	4.4
petal.length	3.758	1.765	1.0	6.9
petal.width	1.199	0.762	0.1	2.5

Especies: Setosa=50, Versicolor=50, Virginica=50

Limpieza de datos.

Valores nulos.

sepal.length: 0

sepal.width: 0

petal.length: 0

petal.width: 0

variety: 0

Registros duplicados.

Índice	sepal.length	sepal.width	petal.length	petal.width	Variety
101	5.8	2.7	5.1	1.9	Virginica
142	5.8	2.7	5.1	1.9	Virginica

Nota: Ambos registros son Virginica idénticas. Biológicamente plausible.

Detección de Outliers (Método IQR)

Variable	Q1	Q3	IQR	Limite inf	Limite Sup	Outliers
sepal.length	5.10	6.40	1.30	3.15	8.35	0
sepal.width	2.80	3.30	0.50	2.05	4.05	4
petal.length	1.60	5.10	3.50	-3.65	10.35	0
petal.width	0.30	1.80	1.50	-1.95	4.05	0

Outliers detectados en sepal.width (índices 15, 32, 33, 60):

Índice 15: 4.4 | Índice 32: 4.1 | Índice 33: 4.2 | Índice 60: 2.0

CONCLUSIÓN: El dataset está limpio. No hay nulos. El duplicado es biológicamente

Los outliers en sepal.width son valores dentro del rango biológico de las especies.

Análisis de componentes principales (PCA)

Estandarización.

Media después de estandarizar: [0.0, 0.0, 0.0, 0.0]

Desviación estándar después de estandarizar: [1.0, 1.0, 1.0, 1.0]

Varianza explicada.

Componente	Varianza	Porcentaje	Acumulada	Porcentaje Acum.
PC1	0.7296	72.96 %	07296	72.96 %
PC2	0.2285	22.85 %	0.9581	95.81 %
PC3	0.0367	3.67 %	0.9948	99.48 %
PC4	0.0052	0.52 %	1.0000	100.00 %

Los DOS PRIMEROS componentes explican el 95.81% de la varianza tot

PC1 explica el 73.0% y PC2 el 22.9%.

Valores Propios (Eigenvalues).

λ1 = 2.9381

λ2 = 0.9202

λ3 = 0.1477

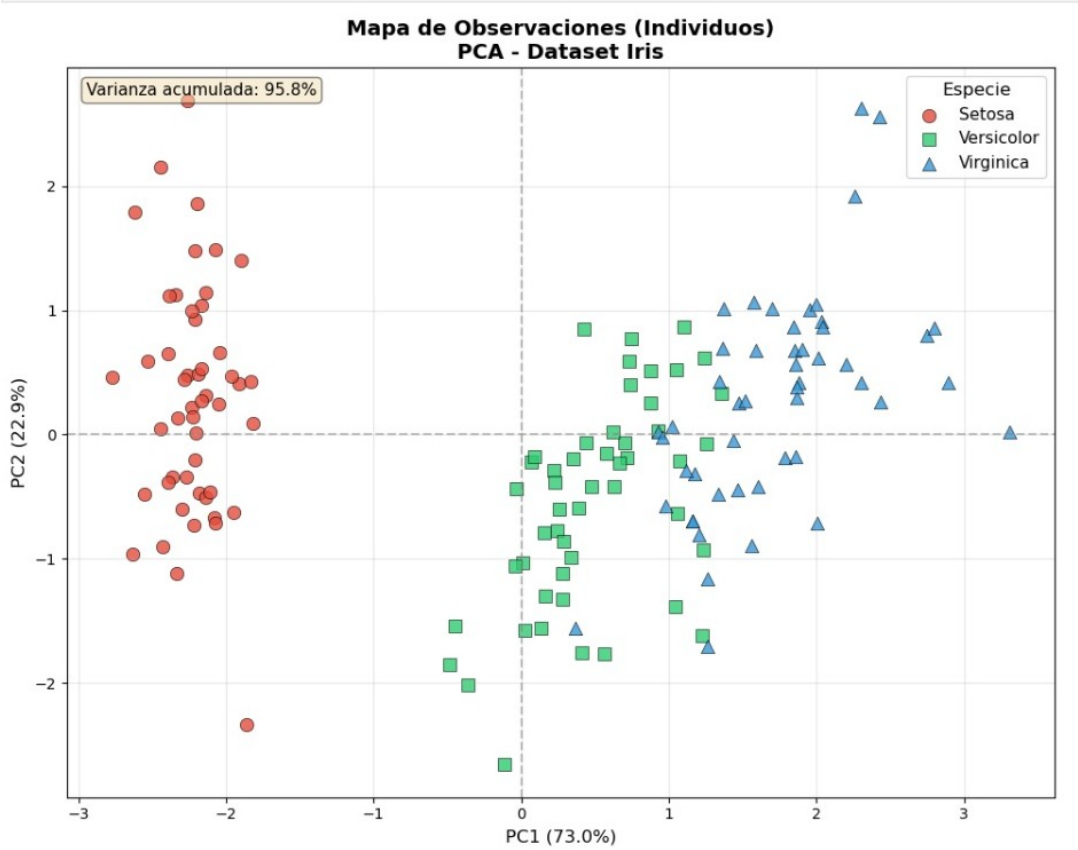
λ4 = 0.0209

Loadings (Cargas/Coordenadas de las variables).

Variable	PC1	PC2	PC3	PC4
sepal.length	0.8932	0.3620	0.2766	-0.0377
sepal.width	-0.4617	0.8857	-0.0939	0.0178
petal.length	0.9949	0.0235	-0.0546	0.1157
petal.width	0.9682	0.0642	-0.2438	-0.0756

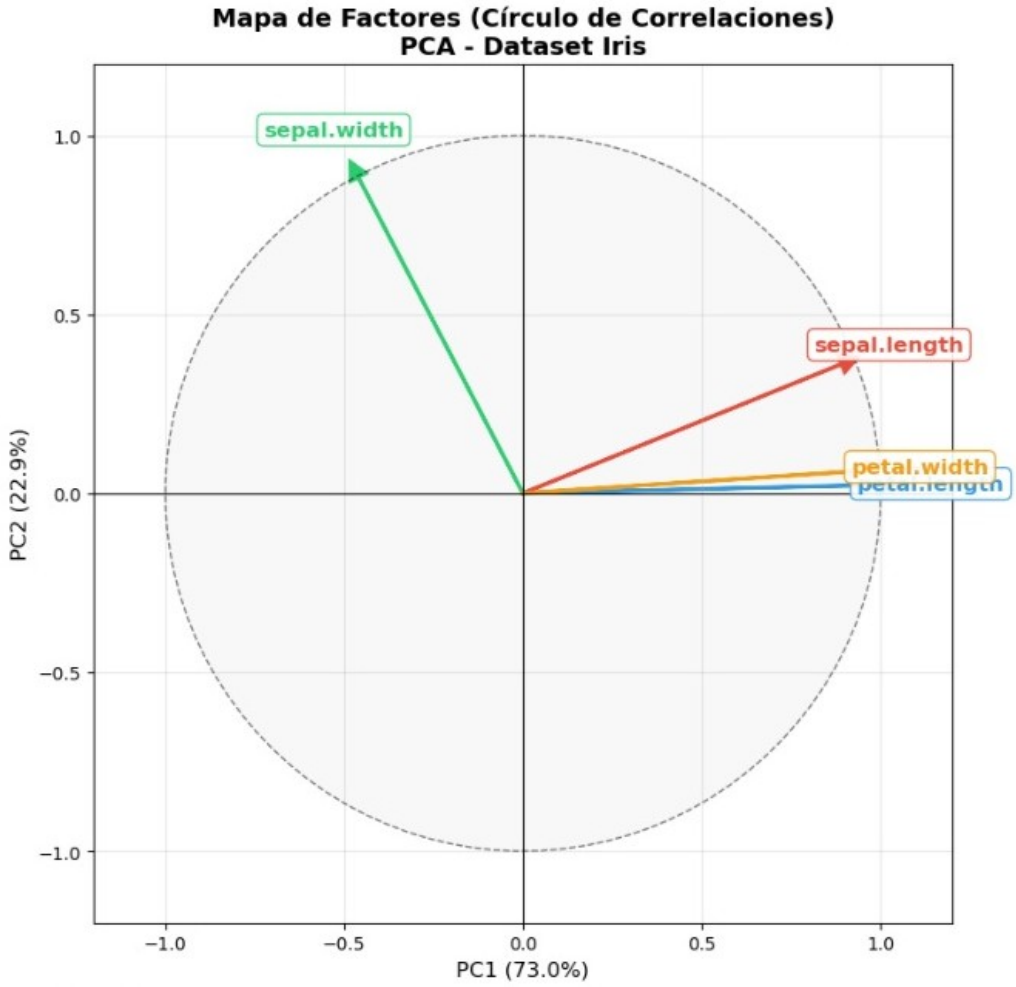
Mapa de observaciones (Individuos)

PCA- Dataset Iris



Mapa de factores

(Círculo de Correlaciones)- PCA Dataset Iris



Comparación, Conclusiones y Corroboración.

Comparación entre Mapa de Observaciones y Mapa de Factores.

Aspecto	Mapa de Observaciones	Contribución de Factores
Qué muestra	Posición de cada flor	Contribución de variables
Setosa	Extrema izquierda (PC1 < 0)	-
Virginica	Derecha (PC1 > 0)	-
Pétalos	-	Máxima contribución a PC1
Ancho sépalo	-	Máxima contribución a PC2

CONCLUSIÓN:

Las flores con PC1 negativo (Setosa) tienen pétalos pequeños. Las de PC1 positivo (Virginica) tienen pétalos grandes. PC2 diferencia por ancho de sépalo.

Corroboración con casos específicos del Dataframe.

Índice	Especie	sepal.length	sepal.width	petal.length	petal.width	PC1	PC2
14 (Setosa)	Setosa	5.8	4.0	1.2	0.2	-2.68	+1.77
101 (Virginica)	Virginica	5.8	2.7	5.1	1.9	+1.90	-0.36
132 (Virginica)	Virginica	7.9	3.8	6.4	2.0	+3.08	+1.67

INTERPRETACIÓN:

- Índice 14 (Setosa): PC1=-2.68 por pétalos pequeños (1.2, 0.2). PC2=+1.77 por sépalo ancho (4.0).
-

- Índice 132 (Virginica): PC1=+3.08 por pétalos grandes (6.4, 2.0). PC2=+1.67 por sépalo ancho (3.8).

- Los resultados del PCA se corroboran perfectamente con los valores originales del DataFrame.